

ĐẠI HỌC TRÀ VINH
TRƯỜNG KỸ THUẬT VÀ CÔNG NGHỆ



ISO 9001:2015

THẠCH THỊ XUÂN LINH

XÂY DỰNG HỆ THỐNG GỢI Ý ĐIỂM DU LỊCH
QUỐC TẾ DỰA TRÊN KHAI PHÁ DỮ LIỆU

ĐỒ ÁN TỐT NGHIỆP
NGÀNH CÔNG NGHỆ THÔNG TIN

Vĩnh Long, tháng 6 năm 2026

ĐẠI HỌC TRÀ VINH
TRƯỜNG KỸ THUẬT VÀ CÔNG NGHỆ

XÂY DỰNG HỆ THỐNG GỢI Ý ĐIỂM DU LỊCH
QUỐC TẾ DỰA TRÊN KHAI PHÁ DỮ LIỆU

ĐỒ ÁN TỐT NGHIỆP
NGÀNH CÔNG NGHỆ THÔNG TIN

Sinh viên thực hiện: **THẠCH THỊ XUÂN LINH**

Lớp: **DA22TTA**

Mã số sinh viên: **110122013**

Giảng viên hướng dẫn: **ThS. PHẠM THỊ TRÚC MAI**

Vĩnh Long, tháng 6 năm 2026

BẢN NHẬN XÉT ĐỒ ÁN TỐT NGHIỆP

(Dành cho người hướng dẫn)

Ngành: Công nghệ Thông tin

Họ và tên Giáo viên hướng dẫn: Phạm Thị Trúc Mai

Đơn vị công tác: Trường Kỹ thuật và Công nghệ

Họ và tên sinh viên: Thạch Thị Xuân Linh MSSV: 110122013

Tên đề tài: Xây dựng hệ thống gợi ý điểm du lịch quốc tế dựa trên khai phá dữ liệu.

1. Tinh thần, thái độ học tập, nghiên cứu của sinh viên:

.....
.....

2. Khả năng nghiên cứu khoa học:

.....
.....

3. Hình thức và nội dung của đồ án:

.....
.....

4. Kết luận:

.....
.....

Vĩnh Long, ngày tháng năm 2026

Giảng viên hướng dẫn

(Ký & ghi rõ họ tên)

LỜI CAM ĐOAN

Tôi xin cam đoan rằng đồ án tốt nghiệp với đề tài “Xây dựng hệ thống gợi ý điểm du lịch quốc tế” là công trình nghiên cứu do chính tôi thực hiện dưới sự hướng dẫn của cô Phạm Thị Trúc Mai. Tất cả các số liệu, kết quả và nội dung trình bày trong đồ án này là trung thực và là sản phẩm của quá trình lao động học thuật nghiêm túc của cá nhân tôi. Mọi tài liệu tham khảo đều đã được trích dẫn rõ ràng và đầy đủ theo quy định. Tôi xin chịu hoàn toàn trách nhiệm về tính xác thực và nguyên bản của công trình nghiên cứu này.

Vĩnh Long, ngày ... tháng ... năm 2026

Sinh viên thực hiện

Thạch Thị Xuân Linh

LỜI CẢM ƠN

Để hoàn thành đồ án tốt nghiệp với đề tài “**Xây dựng hệ thống gợi ý điểm du lịch quốc tế dựa trên khai phá dữ liệu**” một cách trọn vẹn, bên cạnh sự nỗ lực của bản thân, em đã nhận được rất nhiều sự hỗ trợ, hướng dẫn và động viên quý báu từ quý Thầy Cô và gia đình.

Lời đầu tiên, em xin bày tỏ lòng biết ơn sâu sắc nhất đến Cô Phạm Thị Trúc Mai – người giảng viên đã trực tiếp hướng dẫn, tận tình chỉ bảo và định hướng cho em trong suốt quá trình nghiên cứu và thực hiện đề tài. Những lời khuyên chuyên môn sâu sắc và sự tận tâm của Cô chính là kim chỉ nam giúp em vượt qua những khó khăn về mặt thuật toán cũng như kỹ thuật để hoàn thiện hệ thống này.

Em xin chân thành cảm ơn quý Thầy Cô thuộc Trường Kỹ thuật và Công nghệ – Đại học Trà Vinh đã truyền đạt cho em những kiến thức nền tảng và chuyên sâu quý báu về Công nghệ thông tin trong suốt các năm học tập tại trường. Những bài học trên giảng đường chính là bệ phóng vững chắc giúp em có đủ tự tin và năng lực để hiện thực hóa một hệ thống mang tính thực tiễn cao.

Cuối cùng, em xin kính chúc quý Thầy Cô luôn dồi dào sức khỏe, hạnh phúc và gặt hái được nhiều thành công hơn nữa trong sự nghiệp giảng dạy và nghiên cứu khoa học cao quý!

Em rất mong nhận được những ý kiến đóng góp, nhận xét từ quý Thầy Cô để hệ thống ngày càng được tối ưu và hoàn thiện hơn.

Em xin chân thành cảm ơn!

Vĩnh Long, ngày ... tháng ... năm 2026

Sinh viên thực hiện

Thạch Thị Xuân Linh

MỤC LỤC

BẢN NHẬN XÉT ĐỒ ÁN TỐT NGHIỆP	i
LỜI CAM ĐOAN	ii
LỜI CẢM ƠN	iii
DANH MỤC TỪ VIẾT TẮT.....	vii
DANH MỤC BẢNG BIỂU	ix
DANH MỤC HÌNH ẢNH	x
CHƯƠNG MỞ ĐẦU	xi
CHƯƠNG 1. TỔNG QUAN NGHIÊN CỨU.....	1
1.1 Bối cảnh nghiên cứu và xu hướng cá nhân hóa trong du lịch quốc tế.....	1
1.2 Đánh giá các nghiên cứu liên quan về hệ thống gợi ý du lịch	1
1.3 Khoảng trống nghiên cứu.....	2
1.4 Định hướng tiếp cận và giải pháp của đề tài.....	2
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT	3
2.1 Khai phá dữ liệu	3
2.1.1 Khái niệm khai phá dữ liệu	3
2.1.2 Các bước quan trọng khi khai phá dữ liệu	3
2.1.3 Ứng dụng của khai phá dữ liệu	3
2.1.4 Quy trình KDD.....	4
2.2 Khai phá luật kết hợp và thuật toán Apriori.....	5
2.2.1 Khái niệm luật kết hợp	5
2.2.2 Nguyên lý của thuật toán Apriori.....	7
2.2.3 Các bước thực hiện thuật toán Apriori.....	7
2.3 Phân cụm K-Means Clustering	8
2.3.1 Khái niệm phân cụm dữ liệu	8
2.3.2 Thuật toán K-Means.....	8
2.3.3 Phương pháp Elbow xác định số cụm K tối ưu	10
2.4 Các phương pháp lọc.....	11
2.4.1 Khái niệm hệ thống gợi ý.....	11
2.4.2 Lọc theo nội dung (Content-Based Filtering)	12

2.4.3 TF-IDF Vectorizer	13
2.4.4 Độ đo Cosine Similarity	15
2.4.5 Lọc cộng tác (Collaborative Filtering)	16
2.4.6 Hệ thống gợi ý lai (Hybrid Recommendation)	16
2.5 Mô hình ngôn ngữ lớn Gemini	18
2.5.1 Tổng quan về mô hình ngôn ngữ lớn	18
2.5.2 Gemini API của Google	19
2.5.3 Kỹ thuật Prompt	20
2.6 Các công nghệ phát triển hệ thống	20
2.6.1 Ngôn ngữ Python	20
2.6.2 Backend	21
2.6.3 Sơ đồ kiến trúc tổng thể của hệ thống	21
2.6.4 Frontend	23
2.6.5 Cơ sở dữ liệu – MongoDB	24
2.6.6 Thư viện bản đồ – Leaflet.js	25
2.6.7 Nguồn dữ liệu	25
2.6.8 Thư viện Python sử dụng trong hệ thống	26
CHƯƠNG 3. HIỆN THỰC HÓA NGHIÊN CỨU	27
3.1 Mô tả bài toán	27
3.2 Kiến trúc tổng thể hệ thống	29
3.3 Thu thập dữ liệu và xử lý dữ liệu	30
3.3.1 Nguồn, quy mô dữ liệu thô và schema dữ liệu sau khi chuẩn hóa	31
3.3.2 Quy trình tiền xử lý dữ liệu	32
3.3.3 Thống kê mô tả dữ liệu thô và kết quả tiền xử lý	34
3.3.4 Quy trình mã hóa giao dịch bằng ma trận nhị phân cho Apriori	37
3.3.5 Quy trình chuẩn hóa đặc trưng số cho K-Means	37
3.4 Thiết kế hệ thống	38
3.4.1 Thiết kế thuật toán Hybrid Recommender	38
3.4.2 Thiết kế API	44
3.5 Sơ đồ phân rã chức năng	46

CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM.....	49
4.1 Môi trường thực nghiệm	49
4.2 Kết quả khai phá dữ liệu	49
4.2.1 Kết quả thuật toán Apriori	51
4.2.2 Kết quả thuật toán K-Means Clustering.....	54
4.2.3 Liên kết giữa kết quả khai phá dữ liệu và cơ chế tính điểm gợi ý	56
4.2.4 Đánh giá định tính mô hình Hybrid Recommendation	56
4.3 Kết quả giao diện hệ thống	56
4.3.1 Trang chủ hệ thống	57
4.3.2 Trang các điểm đến	58
4.3.3 Trang chi tiết điểm đến	59
4.3.4 Trang bản đồ thế giới	61
4.3.5 Trang gợi ý hành trình.....	62
4.3.6 Trang thống kê hệ thống	65
4.4 Đánh giá chung	67
CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN.....	68
5.1 Kết quả đạt được	68
5.2 Hạn chế.....	68
5.3 Hướng phát triển	69
DANH MỤC TÀI LIỆU THAM KHẢO	70

DANH MỤC TỪ VIẾT TẮT

Từ viết tắt	Viết đầy đủ (Tiếng Anh)	Ý nghĩa (Tiếng Việt)
AI	Artificial Intelligence	Trí tuệ nhân tạo
API	Application Programming Interface	Giao diện lập trình ứng dụng
ARM	Association Rule Mining	Khai phá luật kết hợp
ASGI	Asynchronous Server Gateway Interface	Giao diện cổng máy chủ bất đồng bộ
CBF	Content-Based Filtering	Lọc theo nội dung
CF	Collaborative Filtering	Lọc cộng tác
CRUD	Create, Read, Update, Delete	Thêm, đọc, cập nhật và xóa dữ liệu
CSV	Comma-Separated Values	Định dạng tệp dữ liệu phân tách bằng dấu phẩy
HTTP	HyperText Transfer Protocol	Giao thức truyền tải siêu văn bản
JSON	JavaScript Object Notation	Định dạng trao đổi dữ liệu
JWT	JSON Web Token	Chuẩn tạo mã thông báo xác thực
KDD	Knowledge Discovery in Databases	Quy trình khám phá tri thức trong cơ sở dữ liệu
KPI	Key Performance Indicator	Chỉ số đánh giá hiệu quả
LLM	Large Language Model	Mô hình ngôn ngữ lớn
ML	Machine Learning	Học máy
NLP	Natural Language Processing	Xử lý ngôn ngữ tự nhiên
NoSQL	Not Only SQL	Hệ quản trị cơ sở dữ liệu phi quan hệ
OOP	Object-Oriented Programming	Lập trình hướng đối tượng
OSM	OpenStreetMap	Dự án bản đồ mã nguồn mở
REST	Representational State Transfer	Kiến trúc chuyển trạng thái đại diện
SDK	Software Development Kit	Bộ công cụ phát triển phần mềm
SPA	Single Page Application	Ứng dụng trang đơn
SSE	Sum of Squared Errors	Tổng bình phương sai số
TF-IDF	Term Frequency – Inverse Document Frequency	Kỹ thuật biểu diễn và trọng số hóa văn bản
UI	User Interface	Giao diện người dùng
URL	Uniform Resource Locator	Địa chỉ định vị tài nguyên trên Internet
UX	User Experience	Trải nghiệm người dùng

Xây dựng hệ thống gợi ý điểm du lịch quốc tế dựa trên khai phá dữ liệu

Từ viết tắt	Viết đầy đủ (Tiếng Anh)	Ý nghĩa (Tiếng Việt)
UNESCO	United Nations Educational, Scientific and Cultural Organization	Tổ chức Giáo dục, Khoa học và Văn hóa của Liên Hợp Quốc
WSGI	Web Server Gateway Interface	Giao diện công máy chủ web

DANH MỤC BẢNG BIỂU

Bảng 2.1 Ý nghĩa của các giá trị Lift	6
Bảng 3.1 Bảng dữ liệu thô được chuẩn hóa và tổ chức lại theo schema thống nhất	32
Bảng 3.2 Dữ liệu thô	34
Bảng 3.3 Các biến số trên tập điểm đến gốc	35
Bảng 3.4 Kết quả sau khi làm sạch và tiền xử lý dữ liệu.....	36
Bảng 3.5 Mô tả các bước nói lỏng của cơ chế Soft Filtering.....	43
Bảng 3.6 Các endpoint chính của hệ thống.....	44
Bảng 4.1 Cấu hình môi trường thực nghiệm của hệ thống	49
Bảng 4.2 Tham số cấu hình thuật toán Apriori	51
Bảng 4.3 Kết quả thực thi thuật toán Apriori.....	52
Bảng 4.4 Một số luật kết hợp tiêu biểu	53
Bảng 4.5 Đặc trưng các cụm K-Means	54

DANH MỤC HÌNH ẢNH

Hình 2.1 Quy trình KDD.....	4
Hình 2.2 Phân loại các phương pháp gợi ý	12
Hình 3.1 Sơ đồ kiến trúc tổng thể hệ thống	22
Hình 3.2 Sơ đồ luồng xử lý dữ liệu.....	29
Hình 3.3 Quy trình tiền xử lý dữ liệu.....	33
Hình 3.4 Sơ đồ phân rã chức năng	47
Hình 4.1 Phân phối Avg Rating và Avg Cost/Day trên dữ liệu thô.....	50
Hình 4.2 Phân bố điểm đến theo mức chi phí, loại hình du lịch và châu lục sau khi làm sạch và gán nhãn đặc trưng (1.257 điểm đến).....	50
Hình 4.3 Top 20 thuộc tính có support cao nhất trong ma trận giao dịch	52
Hình 4.4 Phân tích chất lượng luật Apriori: tương quan Support–Confidence theo Lift (trái) và phân phối Lift của toàn bộ luật (phải)	54
Hình 4.5 Kết quả phân cụm K-Means (K=5) trên 359 điểm đến đã hoàn tất làm sạch: phân bố Cost vs Rating theo cụm (trái) và số điểm đến mỗi cụm (phải)	54
Hình 4.6 Giao diện trang chủ	57
Hình 4.7 Trang điểm đến	58
Hình 4.8 Trang chi tiết điểm đến	60
Hình 4.9 Trang bản đồ	61
Hình 4.10 Trang gợi ý hành trình phân chọn mùa	62
Hình 4.11 Trang gợi ý hành trình chọn phong cách du lịch	63
Hình 4.12 Trang gợi ý hành trình chọn ngân sách.....	64
Hình 4.13 Trang gợi ý hành trình hiển thị ra gợi ý cho người dùng khi đã chọn đủ các tiêu chí.....	65
Hình 4.14 Trang thống kê hệ thống	66

CHƯƠNG MỞ ĐẦU

Lý do chọn đề tài

Sự phát triển của công nghệ số đã giúp người dùng dễ dàng tiếp cận thông tin về các điểm đến du lịch trên thế giới. Tuy nhiên, số lượng thông tin ngày càng lớn và phân tán trên nhiều nền tảng khiến việc tìm kiếm, so sánh và lựa chọn điểm đến phù hợp trở nên khó khăn. Người dùng không chỉ quan tâm đến mức độ nổi tiếng của địa điểm mà còn cân nhắc nhiều yếu tố như mùa du lịch, ngân sách, loại hình trải nghiệm và khu vực địa lý.

Hệ thống gợi ý có thể hỗ trợ người dùng xử lý lượng thông tin lớn và lựa chọn các đối tượng phù hợp với nhu cầu cá nhân. Việc kết hợp lọc theo nội dung, lọc cộng tác và tri thức được khai phá từ dữ liệu giúp tận dụng ưu điểm của nhiều phương pháp thay vì chỉ phụ thuộc vào một kỹ thuật riêng lẻ [29].

Bên cạnh đó, các mô hình ngôn ngữ lớn như Gemini cho phép người dùng nhập yêu cầu bằng ngôn ngữ tự nhiên. Mô hình có thể hỗ trợ trích xuất các tiêu chí từ câu hỏi và tạo phản hồi dễ hiểu, trong khi danh sách điểm đến vẫn được xác định bằng dữ liệu và thuật toán của hệ thống [7].

Từ những vấn đề trên, đề tài lựa chọn xây dựng hệ thống gợi ý điểm đến du lịch quốc tế dựa trên khai phá dữ liệu. Hệ thống kết hợp Apriori, K-Means, Content-Based Filtering, Collaborative Filtering và Gemini API nhằm hỗ trợ người dùng tìm kiếm điểm đến phù hợp, đồng thời cung cấp giao diện web và bản đồ tương tác để trực quan hóa kết quả.

Mục tiêu nghiên cứu

Xây dựng hệ thống gợi ý điểm du lịch quốc tế theo mùa dựa trên khai phá dữ liệu, có khả năng đề xuất các địa điểm phù hợp nhất với điều kiện thời tiết, chi phí và loại hình du lịch của người dùng.

Áp dụng thuật toán khai phá luật kết hợp Apriori để phát hiện các mối quan hệ tiềm ẩn giữa các yếu tố du lịch như mùa, khí hậu, loại hình, điểm đến từ đó xây dựng kho tri thức phục vụ gợi ý.

Sử dụng K-Means Clustering để phân nhóm các quốc gia và thành phố có đặc điểm khí hậu, chi phí tương đồng, hỗ trợ việc gợi ý các điểm đến thay thế phù hợp.

Tích hợp Gemini API để xây dựng chatbot NLP có khả năng hiểu câu hỏi tự nhiên, trích xuất thực thể ngữ nghĩa và sinh câu trả lời thông minh kèm giải thích dựa trên luật khai phá.

Phát triển giao diện web với ReactJS và Tailwind CSS, tích hợp bản đồ Leaflet.js hiển thị bản đồ trực quan.

Phạm vi nghiên cứu

Về phạm vi dữ liệu: đề tài tập trung vào dữ liệu du lịch quốc tế, bao gồm các điểm đến phổ biến trên toàn thế giới. Dữ liệu được thu thập từ các bộ dữ liệu công khai trên nền tảng Kaggle và các API mở.

Về phạm vi kỹ thuật: hệ thống tập trung vào bốn nhóm kỹ thuật chính là khai phá luật kết hợp, phân cụm, lọc theo nội dung và chatbot NLP sử dụng Gemini API.

Về phạm vi ứng dụng: hệ thống được xây dựng dưới dạng ứng dụng web, giao diện tối ưu cho người dùng cá nhân muốn tìm kiếm và khám phá điểm đến du lịch quốc tế phù hợp với nhu cầu và điều kiện của mình.

Đối tượng nghiên cứu

Các kỹ thuật khai phá dữ liệu: thuật toán Apriori, K-Means Clustering và Content-Based Filtering. Mô hình ngôn ngữ lớn Gemini API và ứng dụng trong phân tích ngữ nghĩa, trích xuất thực thể và sinh văn bản tự nhiên. Dữ liệu du lịch đa nguồn: dữ liệu điểm tham quan, đánh giá người dùng, lễ hội quốc tế, thời tiết lịch sử từ Kaggle và các API. Các công nghệ phát triển ứng dụng web hiện đại: FastAPI, ReactJS, MongoDB và Leaflet.js.

Phương pháp nghiên cứu

Phương pháp lý thuyết: nghiên cứu cơ sở lý thuyết về kỹ thuật data mining, bao gồm khai phá luật kết hợp và phân cụm dữ liệu. Nghiên cứu cơ chế hoạt động của Gemini API, kỹ thuật prompt engineering cho bài toán trích xuất thực thể và sinh văn bản. Nghiên cứu kiến trúc RESTful API với FastAPI và các công nghệ frontend hiện đại.

Phương pháp thực nghiệm: thu thập và làm sạch dữ liệu du lịch, thời tiết lịch sử, lễ hội từ các nguồn Kaggle và API mở. Tiền xử lý dữ liệu: chuẩn hóa tọa độ địa

Xây dựng hệ thống gợi ý điểm du lịch quốc tế dựa trên khai phá dữ liệu

lý, chuẩn hóa định dạng thời gian, mã hóa giao dịch. Chạy thuật toán Apriori với điều chỉnh tham số min_support, min_confidence, min_lift, lưu tập luật vào MongoDB. Chạy K-Means Clustering, xác định số cụm tối ưu bằng Elbow Method, lưu nhãn cụm vào MongoDB. Xây dựng mô-đun NLP, thiết kế prompt cho Gemini API để trích xuất thực thể, viết hàm khớp luật và tính cosine similarity cho lọc nội dung. Xây dựng REST API với FastAPI kết nối mô-đun khai phá và mô-đun NLP, phát triển giao diện ReactJS và Leaflet.

CHƯƠNG 1. TỔNG QUAN NGHIÊN CỨU

1.1 Bối cảnh nghiên cứu và xu hướng cá nhân hóa trong du lịch quốc tế

Sự phát triển của công nghệ số đã tạo ra một lượng lớn thông tin về quốc gia, thành phố và các điểm đến du lịch trên thế giới. Người dùng có thể dễ dàng tiếp cận thông tin về chi phí, mùa du lịch, loại hình trải nghiệm, đánh giá và vị trí địa lý. Tuy nhiên, dữ liệu được phân tán trên nhiều nguồn khác nhau, khiến quá trình tìm kiếm, so sánh và lựa chọn điểm đến phù hợp mất nhiều thời gian.

Bên cạnh đó, nhu cầu du lịch ngày càng có xu hướng cá nhân hóa. Người dùng không chỉ lựa chọn điểm đến dựa trên mức độ nổi tiếng mà còn quan tâm đến ngân sách, thời gian, mùa du lịch và loại hình trải nghiệm. Vì vậy, hệ thống gợi ý có vai trò hỗ trợ phân tích thông tin và xác định các điểm đến phù hợp với nhu cầu của từng người dùng [2], [8], [34].

1.2 Đánh giá các nghiên cứu liên quan về hệ thống gợi ý du lịch

Hệ thống gợi ý là một lĩnh vực nghiên cứu quan trọng trong khoa học máy tính và trí tuệ nhân tạo, với mục tiêu hỗ trợ người dùng tìm kiếm và lựa chọn thông tin phù hợp với nhu cầu cá nhân.

Trong lĩnh vực du lịch, nhiều phương pháp đã được áp dụng để xây dựng hệ thống gợi ý. Một trong những phương pháp phổ biến là khai phá luật kết hợp, cho phép phát hiện các mối quan hệ thường xuyên xuất hiện giữa các yếu tố như mùa du lịch, loại hình trải nghiệm và điểm đến. Phương pháp này giúp khai thác tri thức tiềm ẩn từ dữ liệu du lịch và hỗ trợ việc đưa ra gợi ý hợp lý.

Phương pháp phân cụm dữ liệu cũng được sử dụng rộng rãi để nhóm các điểm đến có đặc điểm tương đồng. Các tiêu chí phân cụm thường bao gồm điều kiện khí hậu, chi phí, mức độ phổ biến hoặc các chỉ số kinh tế – xã hội. Việc phân nhóm này giúp hệ thống xác định các điểm đến thay thế phù hợp cho người dùng.

Các phương pháp gợi ý dựa trên nội dung cũng đóng vai trò quan trọng trong việc cá nhân hóa kết quả. Phương pháp này dựa trên việc so sánh đặc trưng của điểm đến với sở thích của người dùng, từ đó xác định mức độ phù hợp.

Sự phát triển của các mô hình ngôn ngữ lớn đã mở ra một hướng tiếp cận mới cho hệ thống gợi ý. Các mô hình này có khả năng xử lý ngôn ngữ tự nhiên, giúp người dùng tương tác với hệ thống bằng câu hỏi hoặc yêu cầu thông thường.

1.3 Khoảng trống nghiên cứu

Qua các hướng tiếp cận đã khảo sát, có thể nhận thấy mỗi phương pháp đều có ưu điểm và hạn chế riêng. Lọc theo nội dung phụ thuộc vào dữ liệu mô tả; lọc cộng tác cần đủ dữ liệu đánh giá; Apriori chỉ phát huy hiệu quả khi khai phá được các luật phù hợp; còn K-Means chủ yếu hỗ trợ phân nhóm mà không trực tiếp tạo ra thứ hạng gợi ý.

Việc kết hợp lọc theo nội dung, lọc cộng tác và luật kết hợp trong cùng một cơ chế tính điểm có thể giúp tận dụng nhiều nguồn thông tin hơn. Đồng thời, kết quả phân cụm có thể hỗ trợ tìm các điểm đến thay thế mà không làm thay đổi điểm xếp hạng chính.

Việc hỗ trợ truy vấn tiếng Việt bằng ngôn ngữ tự nhiên và trực quan hóa điểm đến trên bản đồ vẫn có thể tiếp tục nghiên cứu và hoàn thiện. Đây là cơ sở để đề tài xây dựng một hệ thống kết hợp khai phá dữ liệu, mô hình gợi ý lai và Gemini API.

1.4 Định hướng tiếp cận và giải pháp của đề tài

Đề tài thu thập dữ liệu điểm đến từ các bộ dữ liệu công khai và API mở. Dữ liệu được kiểm tra, làm sạch, chuẩn hóa và chuyển đổi thành các cấu trúc phù hợp với từng thuật toán. Dữ liệu phân loại được mã hóa thành ma trận giao dịch cho Apriori, dữ liệu số được chuẩn hóa cho K-Means, còn dữ liệu văn bản được biểu diễn bằng TF-IDF.

Mô hình gợi ý trung tâm của hệ thống là Hybrid Recommendation, kết hợp Content-Based Filtering, luật Apriori và Collaborative Filtering. Content-Based Filtering đánh giá mức độ phù hợp giữa yêu cầu và đặc trưng điểm đến; Apriori bổ sung tri thức từ các luật kết hợp; Collaborative Filtering cung cấp tín hiệu cá nhân hóa đối với người dùng có lịch sử đánh giá. K-Means được sử dụng độc lập để hỗ trợ tìm các điểm đến tương tự thuộc cùng cụm.

Gemini API được tích hợp để phân tích truy vấn bằng ngôn ngữ tự nhiên và trích xuất các tiêu chí du lịch. Hệ thống được triển khai dưới dạng ứng dụng web. Kết quả gợi ý được xếp hạng, hiển thị kèm thông tin cơ bản và vị trí địa lý của điểm đến.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT

2.1 Khai phá dữ liệu

2.1.1 Khái niệm khai phá dữ liệu

Khai phá dữ liệu là quá trình sử dụng các phương pháp thống kê, học máy và trí tuệ nhân tạo để phát hiện các mẫu, mối quan hệ hoặc tri thức có giá trị từ tập dữ liệu lớn. Kết quả khai phá dữ liệu có thể được sử dụng để hỗ trợ phân tích, dự đoán và ra quyết định [6], [9].

Khai phá dữ liệu không chỉ thực hiện việc tìm kiếm các mẫu ẩn mà còn liên quan đến quá trình làm sạch, lựa chọn và chuyển đổi dữ liệu trước khi áp dụng thuật toán. Các nhiệm vụ phổ biến của khai phá dữ liệu gồm khai phá luật kết hợp, phân cụm, phân loại, dự báo và phát hiện bất thường.

Trong đề tài, khai phá dữ liệu được sử dụng để phát hiện mối quan hệ giữa các thuộc tính du lịch bằng thuật toán Apriori và phân nhóm các điểm đến có đặc điểm tương đồng bằng thuật toán K-Means. Kết quả thu được được sử dụng làm cơ sở cho hệ thống gợi ý điểm du lịch quốc tế.

2.1.2 Các bước quan trọng khi khai phá dữ liệu

Quá trình khai phá dữ liệu thường bao gồm các bước chính: thu thập dữ liệu, làm sạch và tích hợp dữ liệu, lựa chọn các thuộc tính cần thiết, chuyển đổi dữ liệu sang định dạng phù hợp, áp dụng thuật toán khai phá, đánh giá kết quả và trình bày tri thức thu được.

Các bước trên không hoàn toàn tách biệt mà có thể được thực hiện lặp lại. Khi kết quả chưa đáp ứng yêu cầu, dữ liệu hoặc tham số của thuật toán có thể được điều chỉnh để nâng cao chất lượng khai phá.

Quy trình tổ chức đầy đủ các bước từ dữ liệu thô đến tri thức được gọi là quy trình khám phá tri thức trong cơ sở dữ liệu.

2.1.3 Ứng dụng của khai phá dữ liệu


Khai phá dữ liệu được ứng dụng trong nhiều lĩnh vực như tài chính, thương mại điện tử, phát hiện gian lận, phân tích hành vi khách hàng và xây hệ thống gợi ý.

Trong lĩnh vực du lịch, khai phá dữ liệu giúp phân tích thông tin về điểm đến, mùa du lịch, chi phí, loại hình trải nghiệm và hành vi người dùng. Từ đó, hệ thống có thể phát hiện các mối quan hệ tiềm ẩn và đưa ra những gợi ý phù hợp hơn với nhu cầu cá nhân.

Trong phạm vi đề tài, khai phá dữ liệu được ứng dụng vào ba nhiệm vụ chính: khai phá luật kết hợp bằng Apriori, phân nhóm điểm đến bằng K-Means và hỗ trợ xây dựng mô hình gợi ý lai.

2.1.4 Quy trình KDD

KDD (Knowledge Discovery in Databases) thường có nhiều cách hiểu khác nhau về số bước riêng biệt trong quy trình của nó. Quy trình KDD được mô tả thành năm bước gồm [4], [6], [9]:



Hình 2.1 Quy trình KDD

Bước 1 – Lựa chọn dữ liệu: Xác định và lựa chọn những dữ liệu, bản ghi và thuộc tính phù hợp với mục tiêu nghiên cứu từ các nguồn dữ liệu ban đầu.

Bước 2 – Tiền xử lý dữ liệu: Làm sạch và tích hợp dữ liệu bằng cách xử lý giá trị thiếu, dữ liệu trùng lặp, sai định dạng và những giá trị không nhất quán.

Bước 3 – Chuyển đổi dữ liệu: Chuẩn hóa, mã hóa và chuyển dữ liệu sang cấu trúc phù hợp với từng thuật toán khai phá.

Bước 4 – Khai phá dữ liệu: Áp dụng các thuật toán để phát hiện các mẫu, mối quan hệ hoặc nhóm dữ liệu có ý nghĩa.

Bước 5 – Phân tích và đánh giá kết quả: Đánh giá chất lượng kết quả, diễn giải các mẫu được phát hiện và chuyển chúng thành tri thức phục vụ hỗ trợ ra quyết định.

Trong đề tài, dữ liệu du lịch được lựa chọn từ các nguồn công khai, sau đó được làm sạch, tích hợp và chuẩn hóa bằng Python. Dữ liệu tiếp tục được chuyển đổi thành ma trận giao dịch cho Apriori và tập đặc trưng số cho K-Means. Kết quả khai phá được đánh giá và sử dụng để hỗ trợ hệ thống gợi ý điểm đến du lịch quốc tế.

2.2 Khai phá luật kết hợp và thuật toán Apriori

2.2.1 Khái niệm luật kết hợp

Khai phá luật kết hợp (Association Rule Mining) là phương pháp phát hiện các mối quan hệ thường xuyên xuất hiện giữa các tập mục trong dữ liệu giao dịch. Một luật kết hợp có dạng:

$$A \rightarrow B$$

Trong đó, A là tập điều kiện và B là tập kết quả, với $A \cap B = \emptyset$. Luật trên cho biết khi tập mục A xuất hiện thì tập mục B có khả năng cũng xuất hiện trong cùng giao dịch [1], [10].

$$A \cap B = \emptyset$$

Luật ($A \rightarrow B$) cho biết khi tập mục (A) xuất hiện thì tập mục (B) có khả năng cũng xuất hiện trong cùng một giao dịch.

Trong lĩnh vực du lịch, luật kết hợp có thể được sử dụng để phát hiện mối quan hệ giữa mùa du lịch, ngân sách, loại hình trải nghiệm, khu vực địa lý và điểm đến. Ví dụ, một luật có thể cho biết người dùng lựa chọn ngân sách tiết kiệm thường có xu hướng quan tâm đến các điểm đến thuộc châu Á.

Chất lượng của một luật kết hợp thường được đánh giá thông qua ba độ đo chính gồm Support, Confidence và Lift.

Chất lượng của một luật kết hợp được đánh giá qua ba độ đo chính:

a) Support (Độ hỗ trợ): Là tỷ lệ phần trăm các giao dịch chứa đồng thời cả tập A và tập B so với tổng số giao dịch. Support phản ánh mức độ phổ biến của luật trong toàn bộ dữ liệu [1], [10].

$$Support(A \rightarrow B) = \frac{|T(A \cup B)|}{|T|}$$

Trong đó: A: tập điều kiện; B: tập kết quả; $T(A \cup B)$: số giao dịch chứa đồng thời A và B; T: tổng số giao dịch.

Giá trị Support càng lớn thì luật xuất hiện càng phổ biến trong dữ liệu. Trong đề tài, Support được sử dụng để loại bỏ các luật quá hiếm trước khi tiếp tục đánh giá bằng Confidence và Lift.

b) Confidence (Độ tin cậy): Là tỷ lệ phần trăm các giao dịch chứa A mà cũng chứa B. Confidence đo lường độ chính xác hay độ tin cậy của luật [1], [10].

$$Confidence(A \rightarrow B) = \frac{Support(A \cup B)}{Support(A)}$$

Trong đó: Support(A): độ hỗ trợ của A; Support(A∪B): độ hỗ trợ của tập mục A và B. Confidence biểu diễn xác suất xuất hiện của B khi A đã xuất hiện trong cùng một giao dịch.

Confidence càng cao thì khả năng xuất hiện của (B) khi có (A) càng lớn. Trong đề tài, độ đo này được sử dụng để lựa chọn những luật có khả năng dự đoán phù hợp.

c) Lift (Độ nâng): Đo lường mức độ tương quan thực sự giữa A và B, loại bỏ ảnh hưởng của sự phổ biến riêng lẻ. Lift > 1 cho thấy A và B xuất hiện cùng nhau nhiều hơn so với kỳ vọng ngẫu nhiên [1], [10].

$$Lift(A \rightarrow B) = \frac{Confidence(A \rightarrow B)}{Support(B)}$$

Trong đó: Confidence(A → B): độ tin cậy của luật kết hợp; (Support(B)): độ hỗ trợ của tập mục B; Lift phản ánh mức độ tương quan thực sự giữa A và B sau khi loại bỏ ảnh hưởng của tần suất xuất hiện riêng lẻ của từng tập mục.

Bảng 2.1 Ý nghĩa của các giá trị Lift

Giá trị Lift	Ý nghĩa	Ứng dụng
Lift > 1	A và B có tương quan dương – xuất hiện cùng nhau nhiều hơn kỳ vọng	Luật có giá trị gợi ý cao
Lift = 1	A và B độc lập thống kê với nhau	Luật không có ý nghĩa thực tiễn
Lift < 1	A và B có tương quan âm – hiếm khi xuất hiện cùng nhau	Luật phủ định, ít hữu ích

Trong đề tài, một luật kết hợp chỉ được giữ lại khi đồng thời thỏa mãn các ngưỡng tối thiểu về Support, Confidence và Lift. Điều này giúp loại bỏ các luật ít xuất hiện, có độ tin cậy thấp hoặc không thể hiện mối tương quan có ý nghĩa.

2.2.2 Nguyên lý của thuật toán Apriori

Thuật toán Apriori được xây dựng dựa trên nguyên lý: mọi tập con của một tập mục phổ biến cũng phải là tập mục phổ biến. Ngược lại, nếu một tập mục không phổ biến thì mọi tập cha chứa tập mục đó cũng không phổ biến [1], [10].

Nguyên lý này cho phép thuật toán loại bỏ sớm các tập ứng viên không thỏa mãn ngưỡng Support, từ đó giảm không gian tìm kiếm.

Một luật chỉ được chấp nhận khi thỏa mãn các điều kiện sau [1], [10]:

$$Support \geq MinSupport$$

$$Confidence \geq MinConfidence$$

$$Lift \geq MinLift$$

Trong đó: *MinSupport* là ngưỡng độ hỗ trợ tối thiểu; *MinConfidence* là ngưỡng độ tin cậy tối thiểu; *MinLift* là ngưỡng độ nâng tối thiểu.

Các giá trị ngưỡng được lựa chọn dựa trên đặc điểm, quy mô và mức độ phân bố của tập dữ liệu thực nghiệm.

2.2.3 Các bước thực hiện thuật toán Apriori

Các bước thực thi thuật toán Apriori [10], [20]:

Bước 1: Quét toàn bộ cơ sở dữ liệu giao dịch để tính support của từng item đơn lẻ (1-itemset), loại bỏ các item có support < min_support.

Bước 2: Từ các frequent 1-itemset, sinh ra các candidate 2-itemset bằng cách ghép đôi. Quét lại dữ liệu để tính support và loại bỏ các 2-itemset không đủ ngưỡng.

Bước 3: Lặp lại quá trình sinh candidate và cắt tỉa cho các k-itemset ($k = 3, 4, \dots$) cho đến khi không còn frequent itemset nào được tìm thấy.

Bước 4: Từ tập hợp tất cả frequent itemsets, sinh ra các luật kết hợp và tính confidence. Chỉ giữ lại các luật có confidence $\geq$ min_confidence và lift $\geq$ min_lift.

Apriori có ưu điểm là nguyên lý đơn giản, dễ triển khai và kết quả có khả năng giải thích rõ ràng. Tuy nhiên, thuật toán phải sinh nhiều tập ứng viên và quét dữ liệu nhiều lần nên có thể tốn thời gian và bộ nhớ khi dữ liệu có quy mô lớn hoặc chứa nhiều thuộc tính [1], [10].

Trong đề tài, Apriori được sử dụng để khai phá mối quan hệ giữa các thuộc tính như mùa du lịch, ngân sách, loại hình du lịch, châu lục và quốc gia. Các luật có

ý nghĩa được lưu trữ trong cơ sở dữ liệu và sử dụng làm nguồn tri thức hỗ trợ cho quá trình tính điểm gợi ý.

2.3 Phân cụm K-Means Clustering

2.3.1 Khái niệm phân cụm dữ liệu

Phân cụm dữ liệu là kỹ thuật học máy không giám sát nhằm chia các đối tượng thành những nhóm có đặc điểm tương đồng. Các đối tượng trong cùng một cụm có mức độ giống nhau cao hơn so với các đối tượng thuộc những cụm khác [9], [15].

Phân cụm không yêu cầu dữ liệu được gán nhãn trước và thường được sử dụng để khám phá cấu trúc tiềm ẩn của tập dữ liệu. Trong lĩnh vực du lịch, kỹ thuật này có thể được sử dụng để nhóm các điểm đến theo chi phí, mức đánh giá, mức độ phổ biến hoặc các đặc trưng có liên quan.

Trong đề tài, phân cụm được sử dụng để xác định các nhóm điểm đến tương đồng, từ đó hỗ trợ hệ thống tìm kiếm và đề xuất những điểm đến thay thế phù hợp.

2.3.2 Thuật toán K-Means

K-Means là thuật toán phân cụm chia tập dữ liệu thành (K) cụm [15], [31], mục tiêu của thuật toán là tối thiểu hóa tổng bình phương khoảng cách giữa các điểm dữ liệu và tâm cụm tương ứng:

$$J = \sum_{k=1}^K \sum_{x_i \in C_k} ||x_i - \mu_k||^2$$

Trong đó:

- J: giá trị của hàm mục tiêu cần tối thiểu hóa.
- K: số lượng cụm.
- C_k : cụm dữ liệu thứ (k).
- x_i : điểm dữ liệu thứ (i).
- μ_k : tâm (centroid) của cụm thứ (k).
- $(||x_i - \mu_k||^2)$: bình phương khoảng cách Euclidean từ điểm dữ liệu đến tâm cụm.

Giá trị hàm mục tiêu càng nhỏ thì các điểm dữ liệu trong cùng một cụm càng gần tâm cụm và có mức độ tương đồng cao hơn [15], [31].

$$\mu_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i$$

Trong đó:

- C_k : số lượng điểm dữ liệu thuộc cụm (k).
- x_i : điểm dữ liệu trong cụm.
- μ_k : tâm cụm mới sau khi cập nhật.

Khoảng cách giữa điểm dữ liệu và tâm cụm được tính bằng khoảng cách Euclidean [15], [31]:

$$d(x_i, \mu_k) = \sqrt{\sum_{j=1}^m (x_{ij} - \mu_{kj})^2}$$

Trong đó:

- m : số thuộc tính của dữ liệu.
- x_{ij} : giá trị thuộc tính thứ (j) của điểm dữ liệu.
- μ_{kj} : giá trị thuộc tính thứ (j) của tâm cụm.
- $d(x_i, \mu_k)$: khoảng cách từ điểm dữ liệu đến tâm cụm.

Trong mỗi vòng lặp, thuật toán sẽ tính khoảng cách từ tất cả các điểm dữ liệu đến các tâm cụm, sau đó gán mỗi điểm vào cụm có khoảng cách nhỏ nhất. Quá trình này được lặp lại liên tục cho đến khi các tâm cụm không còn thay đổi hoặc đạt số lần lặp tối đa.

Các bước thực thi thuật toán K-Means [15], [31]:

Bước 1 – Khởi tạo: Chọn ngẫu nhiên K điểm trong không gian dữ liệu làm centroid ban đầu. Phương pháp K-Means++ cải tiến bước này bằng cách chọn các centroid phân tán đều hơn.

Bước 2 – Gán nhãn: Gán mỗi điểm dữ liệu vào cụm có centroid gần nhất theo khoảng cách Euclidean.

Bước 3 – Cập nhật centroid: Tính lại centroid của từng cụm bằng cách lấy giá trị trung bình của tất cả các điểm trong cụm đó.

Bước 4 – Lặp lại: Lặp lại bước 2 và 3 cho đến khi các centroid không thay đổi đáng kể hoặc đạt số vòng lặp tối đa.

K-Means có ưu điểm là nguyên lý đơn giản, tốc độ xử lý tương đối nhanh và phù hợp với dữ liệu số. Tuy nhiên, kết quả phụ thuộc vào số cụm (K), vị trí tâm cụm ban đầu và thang đo của các thuộc tính. Vì vậy, dữ liệu số cần được chuẩn hóa trước khi thực hiện phân cụm.

Trong đề tài, K-Means được sử dụng để phân nhóm các điểm đến có đặc trưng tương đồng. Nhãn cụm hỗ trợ xác định các điểm đến thay thế thuộc cùng nhóm, nhưng không trực tiếp tham gia vào công thức tính điểm cuối cùng của mô hình Hybrid Recommendation.

2.3.3 Phương pháp Elbow xác định số cụm K tối ưu

Phương pháp Elbow được sử dụng để hỗ trợ lựa chọn số cụm (K) phù hợp cho thuật toán K-Means. Phương pháp này thực hiện K-Means với nhiều giá trị (K) khác nhau, sau đó tính tổng bình phương sai số nội cụm SSE (Sum of Squared Errors) cho từng trường hợp [15], [31].

$$SSE = \sum_{k=1}^K \sum_{x_i \in C_k} ||x_i - \mu_k||^2$$

Trong đó:

- SSE: tổng bình phương sai số nội cụm.
- K: số lượng cụm.
- C_k : cụm thứ (k).
- x_i : điểm dữ liệu.
- μ_k : tâm của cụm thứ (k).
- $|x_i - \mu_k|^2$: bình phương khoảng cách Euclidean từ điểm dữ liệu đến tâm cụm.

Khi số cụm (K) tăng, giá trị SSE có xu hướng giảm vì các điểm dữ liệu được chia vào nhiều cụm nhỏ hơn. Tuy nhiên, sau một giá trị nhất định, mức giảm của SSE trở nên không đáng kể. Vị trí mà tốc độ giảm SSE bắt đầu chậm lại tạo thành điểm gãy trên biểu đồ và được gọi là điểm khuỷu tay.

Quy trình áp dụng phương pháp Elbow gồm:

- Thực hiện K-Means với các giá trị (K) trong một khoảng xác định;
- Tính SSE tương ứng với từng giá trị (K);
- Biểu diễn các giá trị SSE trên biểu đồ;

- Chọn giá trị (K) tại vị trí khuỷu tay.

Phương pháp Elbow giúp cân bằng giữa chất lượng phân cụm và độ phức tạp của mô hình. Bên cạnh đó, Silhouette Score có thể được sử dụng như tiêu chí bổ sung để đánh giá mức độ gắn kết của các điểm trong cùng cụm và mức độ tách biệt giữa các cụm. Giá trị Silhouette càng gần 1 thì cấu trúc phân cụm càng rõ ràng.

Trong đề tài, phương pháp Elbow được sử dụng để hỗ trợ xác định số cụm phù hợp trước khi phân nhóm các điểm đến du lịch bằng thuật toán K-Means.


2.4 Các phương pháp lọc

2.4.1 Khái niệm hệ thống gợi ý

Hệ thống gợi ý (Recommendation System) là hệ thống hỗ trợ người dùng lựa chọn các đối tượng phù hợp từ một tập dữ liệu lớn. Kết quả gợi ý có thể được hình thành dựa trên đặc trưng của đối tượng, hành vi người dùng hoặc sự kết hợp của nhiều nguồn thông tin [12], [29].

Các hệ thống gợi ý thường được chia thành ba hướng tiếp cận chính: lọc theo nội dung, lọc cộng tác và hệ thống gợi ý lai. Lọc theo nội dung dựa trên đặc trưng của đối tượng; lọc cộng tác khai thác dữ liệu đánh giá hoặc lịch sử tương tác của người dùng; hệ thống gợi ý lai kết hợp nhiều phương pháp để nâng cao chất lượng kết quả.

Trong đề tài, mô hình gợi ý lai được xây dựng bằng cách kết hợp Content-Based Filtering, luật kết hợp Apriori và Collaborative Filtering. Thuật toán K-Means được sử dụng để phân nhóm các điểm đến tương đồng, trong khi Gemini API hỗ trợ phân tích yêu cầu của người dùng bằng ngôn ngữ tự nhiên.



Hình 2.2 Phân loại các phương pháp gợi ý

Recommendation System được chia thành 3 hướng tiếp cận chính. Content-Based sử dụng TF-IDF và Cosine Similarity để đo mức độ tương đồng. Collaborative Filtering dựa trên hành vi hoặc đánh giá của người dùng (trong đề tài dùng User-based CF). Hybrid Recommendation kết hợp nhiều phương pháp (đề tài kết hợp Content-Based, Collaborative Filtering và Apriori). Đây cũng chính là hướng tiếp cận được lựa chọn trong đề tài.

2.4.2 Lọc theo nội dung (Content-Based Filtering)

Lọc theo nội dung (Content-Based Filtering – CBF) là phương pháp gợi ý dựa trên đặc trưng của đối tượng và sở thích của người dùng. Phương pháp này phân tích các thuộc tính của những đối tượng người dùng đã quan tâm, sau đó tìm kiếm các đối tượng có đặc điểm tương đồng để đưa ra gợi ý [12], [29].

Khác với lọc cộng tác, CBF không phụ thuộc nhiều vào dữ liệu đánh giá của những người dùng khác mà chủ yếu khai thác thông tin mô tả của chính đối tượng. Vì vậy, phương pháp có thể hoạt động khi hệ thống chưa có nhiều người dùng hoặc dữ liệu tương tác còn hạn chế.

Ưu điểm của CBF là kết quả dễ giải thích, không phụ thuộc nhiều vào dữ liệu cộng đồng và có thể gợi ý cho người dùng mới khi đã biết yêu cầu của họ. Tuy nhiên, chất lượng gợi ý phụ thuộc vào mức độ đầy đủ của dữ liệu mô tả và có thể xảy ra hiện tượng quá chuyên biệt hóa, tức hệ thống chỉ đề xuất những đối tượng gần giống với sở thích đã biết.

Trong đề tài, Content-Based Filtering là thành phần chính dùng để đánh giá mức độ phù hợp giữa yêu cầu của người dùng và đặc trưng của điểm đến. Dữ liệu văn bản được biểu diễn bằng TF-IDF, sau đó Cosine Similarity được sử dụng để tính mức độ tương đồng và hỗ trợ xếp hạng kết quả.

2.4.3 TF-IDF Vectorizer

2.4.3.1 Tiền xử lý dữ liệu

Trước khi áp dụng TF-IDF, dữ liệu văn bản cần được tiền xử lý nhằm loại bỏ các thông tin không cần thiết và chuẩn hóa nội dung. Quá trình tiền xử lý giúp giảm nhiễu trong dữ liệu, tăng chất lượng biểu diễn vector và cải thiện độ chính xác của các thuật toán gợi ý [16], [23], [25].

Các bước tiền xử lý văn bản thường bao gồm:

- (1) Chuyển toàn bộ văn bản về chữ thường (Lowercase).
- (2) Loại bỏ dấu câu, ký tự đặc biệt và khoảng trắng dư thừa.
- (3) Loại bỏ các từ dừng (Stop Words) không mang nhiều ý nghĩa.
- (4) Chuẩn hóa từ và ký tự.
- (5) Tách từ (Tokenization) để phục vụ quá trình vector hóa.

Sau khi tiền xử lý, dữ liệu văn bản được chuyển thành các vector số bằng TF-IDF để phục vụ việc tính toán mức độ tương đồng bằng Cosine Similarity.

2.4.3.2 Khái niệm TF-IDF

TF-IDF (Term Frequency – Inverse Document Frequency) là kỹ thuật biểu diễn văn bản được sử dụng phổ biến trong khai phá dữ liệu và xử lý ngôn ngữ tự nhiên. Phương pháp này chuyển đổi nội dung văn bản thành các vector số để máy tính có thể xử lý và so sánh giữa các tài liệu [16], [30].

TF-IDF đánh giá mức độ quan trọng của một từ dựa trên hai yếu tố: tần suất xuất hiện của từ trong một tài liệu và mức độ phổ biến của từ trong toàn bộ tập tài liệu. Một từ xuất hiện nhiều trong một tài liệu nhưng ít xuất hiện ở các tài liệu khác sẽ có trọng số cao hơn.

2.4.3.3 Term Frequency – TF

Term Frequency (TF) biểu diễn tần suất xuất hiện của một từ trong một tài liệu. Giá trị TF càng lớn thì từ đó càng có mức độ ảnh hưởng đối với nội dung của tài liệu [16], [30].

$$TF(t, d) = \frac{f_{t,d}}{\sum_k f_{k,d}}$$

Trong đó:

- t : từ cần xét.
- d : tài liệu.
- $f_{t,d}$: số lần từ (t) xuất hiện trong tài liệu (d).
- $\sum_k f_{k,d}$: tổng số từ trong tài liệu.

TF càng lớn thì từ đó xuất hiện càng thường xuyên trong tài liệu. Tuy nhiên, TF chưa phản ánh đầy đủ mức độ quan trọng của từ vì một số từ có thể xuất hiện phổ biến trong nhiều tài liệu nhưng không mang nhiều giá trị phân biệt.

2.4.3.4 Inverse Document Frequency – IDF

Inverse Document Frequency (IDF) phản ánh mức độ quan trọng của một từ trong toàn bộ tập tài liệu. Những từ xuất hiện ở nhiều tài liệu sẽ có trọng số thấp, trong khi các từ chỉ xuất hiện ở một số ít tài liệu sẽ có trọng số cao hơn [16], [30], [32].

$$IDF(t) = \log \left(\frac{1 + N}{1 + df(t)} \right) + 1$$

Trong đó:

- N : tổng số tài liệu.
- $df(t)$: số tài liệu có chứa từ (t).
- $+1$ ở tử và mẫu giúp tránh chia cho 0.
- $+1$ phía ngoài giúp trọng số luôn dương.

Việc sử dụng IDF giúp giảm ảnh hưởng của các từ xuất hiện phổ biến trong toàn bộ tập dữ liệu, đồng thời làm nổi bật các từ mang nhiều giá trị phân biệt giữa các tài liệu.

2.4.3.5 Trọng số TF-IDF

Trọng số TF-IDF được xác định bằng tích của TF và IDF, được tính theo công thức sau [16], [30], [32]:

$$TFIDF(t, d) = TF(t, d) \times IDF(t)$$

Trong đó:

- $TFIDF(t, d)$: trọng số của từ t trong tài liệu d .
- $TF(t, d)$: tần suất xuất hiện của từ t trong tài liệu d .
- $IDF(t)$: trọng số phản ánh mức độ quan trọng của từ t trong toàn bộ tập tài liệu.

Trọng số TF-IDF càng lớn thì từ đó càng mang nhiều thông tin đặc trưng cho tài liệu. Ngược lại, những từ xuất hiện phổ biến trong nhiều tài liệu sẽ có trọng số thấp hơn.

Trong đề tài, TF-IDF được sử dụng để chuyển đổi phần mô tả của các điểm đến du lịch thành các vector đặc trưng. Yêu cầu của người dùng cũng được biểu diễn trong cùng một không gian vector. Các vector này là đầu vào của Cosine Similarity để tính mức độ tương đồng giữa yêu cầu người dùng và từng điểm đến.

2.4.4 Độ đo Cosine Similarity

Cosine Similarity là phương pháp đo mức độ tương đồng giữa hai vector dựa trên góc tạo bởi chúng trong không gian nhiều chiều. Khác với khoảng cách Euclidean, Cosine Similarity chủ yếu đánh giá mức độ giống nhau về hướng của hai vector thay vì độ lớn của chúng. Vì vậy, phương pháp này phù hợp với dữ liệu văn bản được biểu diễn bằng TF-IDF [16], [32].

Độ tương đồng Cosine giữa hai vector (A) và (B) được xác định bằng công thức [16], [32]:

$$Cosine(A, B) = \frac{A \cdot B}{||A|| ||B||}$$

Trong đó:

- $Cosine(A, B)$: độ tương đồng giữa hai vector A và B.
- A: vector đặc trưng của điểm đến.
- B: vector đặc trưng của yêu cầu người dùng.
- $A \cdot B$: tích vô hướng của hai vector.

- $\|A\|$: độ dài (chuẩn Euclid) của vector A.
- $\|B\|$: độ dài (chuẩn Euclid) của vector B.

Đối với các vector TF-IDF có giá trị không âm, Cosine Similarity thường nằm trong khoảng từ 0 đến 1. Giá trị càng gần 1 thì hai vector càng tương đồng; giá trị càng gần 0 thì mức độ tương đồng càng thấp.

Trong đề tài, Cosine Similarity được sử dụng để so sánh vector yêu cầu của người dùng với vector đặc trưng của từng điểm đến. Kết quả tính toán là thành phần quan trọng của điểm lọc theo nội dung và được sử dụng để xếp hạng các điểm đến phù hợp.

2.4.5 Lọc cộng tác (Collaborative Filtering)

Lọc cộng tác (Collaborative Filtering – CF) khai thác dữ liệu đánh giá hoặc lịch sử tương tác của nhiều người dùng để đưa ra gợi ý. Phương pháp dựa trên giả định rằng những người dùng hoặc đối tượng có hành vi tương đồng trong quá khứ sẽ tiếp tục có xu hướng tương đồng trong tương lai [11], [29].

Hai hướng chính gồm User-based Collaborative Filtering và Item-based Collaborative Filtering. User-based dựa trên sự tương đồng giữa người dùng, còn Item-based dựa trên sự tương đồng giữa các đối tượng.

Ưu điểm của CF là có khả năng khám phá các đối tượng mới ngoài nội dung người dùng đang tìm kiếm và không yêu cầu mô tả chi tiết của từng đối tượng. Hạn chế là hiện tượng Cold Start và Data Sparsity khi dữ liệu đánh giá chưa đủ lớn.

Trong đề tài, Item-based Collaborative Filtering được sử dụng như một thành phần hỗ trợ. Phương pháp này khai thác dữ liệu đánh giá và lịch sử tương tác để xác định các điểm đến có sự tương đồng, từ đó tăng mức độ cá nhân hóa cho những người dùng đã có lịch sử sử dụng hệ thống.

2.4.6 Hệ thống gợi ý lai (Hybrid Recommendation)

Hệ thống gợi ý lai (Hybrid Recommendation) là phương pháp kết hợp từ hai kỹ thuật gợi ý trở lên nhằm tận dụng ưu điểm và hạn chế nhược điểm của từng phương pháp riêng lẻ. Mô hình này có thể kết hợp đặc trưng của đối tượng, hành vi người dùng và tri thức được khai phá từ dữ liệu để tạo ra kết quả gợi ý phù hợp hơn [11], [12], [29].

Content-Based Filtering có khả năng xác định đối tượng phù hợp với yêu cầu hiện tại của người dùng nhưng có thể tạo ra các kết quả quá giống nhau. Collaborative Filtering có thể khám phá các đối tượng mới dựa trên hành vi cộng đồng nhưng phụ thuộc vào dữ liệu đánh giá. Việc kết hợp các phương pháp giúp nâng cao khả năng cá nhân hóa và giảm ảnh hưởng của các vấn đề như Cold Start và Data Sparsity.

Có nhiều cách xây dựng hệ thống gợi ý lai như kết hợp có trọng số, chuyển đổi giữa các phương pháp hoặc hiển thị đồng thời kết quả từ nhiều mô hình. Trong phạm vi đề tài, hệ thống sử dụng cách kết hợp có trọng số (Weighted Hybrid), trong đó điểm số từ các thành phần gợi ý được tổng hợp để hình thành điểm cuối cùng cho mỗi điểm đến. Cơ chế này phù hợp vì cho phép điều chỉnh mức độ ảnh hưởng của từng phương pháp và dễ giải thích kết quả gợi ý.

Trong phạm vi đề tài, hệ thống sử dụng phương pháp kết hợp có trọng số (Weighted Hybrid) [11], [12], [29] dạng tổng quát của điểm kết hợp được biểu diễn như sau:

$$Score_{hybrid}(i) = \sum_{r=1}^n w_r Score_r(i)$$

Trong đó:

- $Score_{hybrid}(i)$ là điểm tổng hợp của đối tượng (i);
- $Score_r(i)$ là điểm của đối tượng (i) do thành phần gợi ý thứ (r) tạo ra;
- w_r là trọng số thể hiện mức độ ảnh hưởng của thành phần thứ (r);
- n là số thành phần được kết hợp.

Các trọng số thường phải thỏa mãn điều kiện sau [11], [12], [29]:

$$w_r \geq 0, \quad \sum_{r=1}^n w_r = 1$$

Công thức trên là dạng tổng quát của phương pháp kết hợp có trọng số. Các thành phần và trọng số cụ thể phải được lựa chọn phù hợp với đặc điểm dữ liệu và mục tiêu của từng hệ thống.

Mô hình Hybrid của đề tài gồm ba thành phần chính:

- Content-Based Filtering: đóng vai trò chính trong việc xác định mức độ phù hợp giữa yêu cầu của người dùng và đặc trưng của điểm đến;

- Apriori: bổ sung tri thức từ các luật kết hợp đã được khai phá, giúp tăng mức ưu tiên cho các điểm đến có mối liên hệ phù hợp với mùa, ngân sách, loại hình du lịch hoặc khu vực địa lý;
- Collaborative Filtering: hỗ trợ cá nhân hóa kết quả dựa trên dữ liệu đánh giá và lịch sử tương tác của người dùng.

Thuật toán K-Means không trực tiếp tham gia vào công thức tính điểm cuối cùng của mô hình Hybrid mà được sử dụng để phân nhóm các điểm đến có đặc điểm tương đồng. Kết quả phân cụm hỗ trợ hệ thống đề xuất những điểm đến thay thế thuộc cùng nhóm khi cần thiết.

Quá trình gợi ý được thực hiện bằng cách tính điểm phù hợp theo nội dung, bổ sung điểm từ các luật Apriori và tín hiệu từ Collaborative Filtering. Các thành phần sau đó được tổng hợp để xếp hạng và lựa chọn danh sách điểm đến phù hợp nhất.

Ưu điểm của Hybrid Recommendation là khai thác được nhiều nguồn dữ liệu, nâng cao khả năng cá nhân hóa và hạn chế nhược điểm của từng phương pháp đơn lẻ. Tuy nhiên, mô hình có cấu trúc phức tạp hơn và cần lựa chọn cơ chế kết hợp phù hợp với dữ liệu thực tế.

Trong đề tài, công thức tính điểm cuối cùng, các trọng số kết hợp và giá trị tăng cường từ Collaborative Filtering là thiết kế do tác giả đề xuất trên cơ sở lý thuyết về Weighted Hybrid [11], [12], [29].

2.5 Mô hình ngôn ngữ lớn Gemini

2.5.1 Tổng quan về mô hình ngôn ngữ lớn

Mô hình ngôn ngữ lớn (Large Language Model – LLM) là mô hình trí tuệ nhân tạo được huấn luyện trên khối lượng lớn dữ liệu văn bản, có khả năng phân tích ngữ cảnh, hiểu yêu cầu và sinh nội dung bằng ngôn ngữ tự nhiên. LLM được ứng dụng trong nhiều nhiệm vụ như xây dựng chatbot, tóm tắt văn bản, phân loại nội dung, trích xuất thông tin và hỗ trợ tương tác giữa người dùng với hệ thống [2].

Trong hệ thống gợi ý, mô hình ngôn ngữ lớn giúp người dùng diễn đạt nhu cầu bằng câu hỏi tự nhiên thay vì phải lựa chọn toàn bộ tiêu chí thông qua các bộ lọc cố định. Từ nội dung truy vấn, mô hình có thể nhận diện các thông tin như mùa du

lịch, mức ngân sách, loại hình trải nghiệm, quốc gia hoặc khu vực địa lý mà người dùng quan tâm.

Tuy nhiên, kết quả do mô hình ngôn ngữ lớn tạo ra có thể không hoàn toàn chính xác hoặc không ổn định giữa các lần xử lý. Vì vậy, dữ liệu đầu ra cần được kiểm tra về cấu trúc, kiểu dữ liệu và giá trị trước khi sử dụng trong hệ thống.

Trong đề tài, mô hình ngôn ngữ lớn chỉ đảm nhiệm việc phân tích yêu cầu của người dùng và hỗ trợ tạo phản hồi bằng ngôn ngữ tự nhiên. Quá trình lựa chọn, tính điểm và xếp hạng các điểm đến vẫn được thực hiện bởi mô hình Hybrid Recommendation dựa trên dữ liệu và các thuật toán được xây dựng trong hệ thống.

2.5.2 Gemini API của Google

Gemini API là giao diện lập trình do Google cung cấp, cho phép ứng dụng truy cập các mô hình Gemini mà không cần tự xây dựng và huấn luyện mô hình ngôn ngữ từ đầu. Gemini có khả năng tiếp nhận truy vấn bằng ngôn ngữ tự nhiên và trả kết quả dưới dạng văn bản hoặc dữ liệu có cấu trúc [7].

Khả năng trả kết quả theo cấu trúc JSON giúp Backend dễ dàng kiểm tra, chuẩn hóa và chuyển dữ liệu đến mô hình gợi ý. Trong đề tài, Gemini API được sử dụng để trích xuất các tiêu chí từ câu hỏi của người dùng, bao gồm mùa du lịch, mức ngân sách, loại hình du lịch, quốc gia, châu lục và các yêu cầu bổ sung khác.

Thư viện hỗ trợ kết nối Gemini API với Python được cài đặt bằng lệnh sau:

```
pip install google-genai
```

Sau khi cài đặt, hệ thống cần cấu hình API Key được cấp từ Google AI Studio. Khóa truy cập nên được lưu trong biến môi trường thay vì ghi trực tiếp vào mã nguồn nhằm hạn chế nguy cơ lộ thông tin cấu hình.

Gemini API có ưu điểm là khả năng hiểu ngữ cảnh, hỗ trợ tiếng Việt, tích hợp thuận tiện với Python và có thể trả kết quả theo định dạng yêu cầu. Tuy nhiên, quá trình sử dụng phụ thuộc vào kết nối Internet, hạn mức truy cập của dịch vụ và chất lượng của câu lệnh đầu vào.

Trong hệ thống, Gemini không trực tiếp tạo danh sách điểm đến. Các tiêu chí sau khi được trích xuất sẽ được chuyển đến Backend và mô hình Hybrid Recommendation để tiến hành lọc, tính điểm và xếp hạng. Sau khi hệ thống có kết

quả, Gemini có thể hỗ trợ tạo câu trả lời tự nhiên và giải thích ngắn gọn cho người dùng.

2.5.3 Kỹ thuật Prompt

Prompt Engineering là kỹ thuật thiết kế câu lệnh đầu vào nhằm hướng dẫn mô hình ngôn ngữ thực hiện đúng nhiệm vụ và trả kết quả theo định dạng mong muốn. Một prompt phù hợp cần xác định rõ vai trò của mô hình, ngữ cảnh của bài toán, nhiệm vụ cần xử lý, các ràng buộc và cấu trúc kết quả đầu ra [7].

Trong đề tài, prompt được thiết kế để yêu cầu Gemini phân tích câu hỏi của người dùng và trích xuất các thông tin du lịch cần thiết. Kết quả được yêu cầu trả về dưới dạng JSON để Backend có thể dễ dàng kiểm tra và sử dụng.

Backend tiếp nhận kết quả trên, sau đó kiểm tra tên trường, kiểu dữ liệu và các giá trị được trả về trước khi chuyển các tiêu chí đến mô hình gợi ý. Nếu kết quả không đúng cấu trúc hoặc thiếu thông tin, hệ thống có thể sử dụng giá trị mặc định, áp dụng cơ chế xử lý dự phòng hoặc yêu cầu người dùng bổ sung tiêu chí.

Ưu điểm của Prompt Engineering là có thể điều chỉnh cách xử lý của mô hình mà không cần huấn luyện lại. Tuy nhiên, chất lượng phản hồi phụ thuộc nhiều vào mức độ rõ ràng và chặt chẽ của prompt. Vì vậy, hệ thống cần kiểm tra dữ liệu đầu ra thay vì sử dụng trực tiếp toàn bộ nội dung do Gemini tạo ra.

2.6 Các công nghệ phát triển hệ thống

2.6.1 Ngôn ngữ Python

Python là ngôn ngữ lập trình bậc cao, cú pháp dễ đọc và có hệ sinh thái thư viện mạnh cho khoa học dữ liệu và phát triển web [25]. Trong đề tài, Python được dùng để tiền xử lý dữ liệu, chạy Apriori, K-Means, TF-IDF, Cosine Similarity và xây dựng Backend.

Môi trường ảo Python được khởi tạo và kích hoạt bằng các lệnh:

```
python -m venv venv  
  
venv\Scripts\activate
```

Các thư viện của dự án được cài đặt bằng lệnh:

```
pip install -r requirements.txt
```

Ưu điểm: dễ học, thư viện phong phú và phù hợp xử lý dữ liệu. Hạn chế: tốc độ thực thi thuần Python thấp hơn ngôn ngữ biên dịch và cần quản lý phiên bản thư viện để tránh xung đột.

2.6.2 Backend

FastAPI là framework Python dùng để xây dựng REST API, hỗ trợ kiểm tra dữ liệu đầu vào và tự động sinh tài liệu API [5]. Uvicorn là máy chủ ASGI dùng để chạy ứng dụng FastAPI [35]. Trong hệ thống, Backend tiếp nhận yêu cầu từ Frontend, xác thực người dùng, truy xuất MongoDB, gọi các thuật toán gợi ý và trả kết quả ở định dạng JSON.

Cài đặt và khởi động:


```
pip install fastapi uvicorn

uvicorn main:app --reload
```

Ưu điểm: hiệu năng tốt, cú pháp gọn và dễ tích hợp thư viện AI. Hạn chế: các chức năng lớn như phân quyền, quản trị và cấu trúc dự án cần được thiết kế thêm; lập trình bất đồng bộ đòi hỏi người phát triển hiểu rõ luồng xử lý.

2.6.3 Sơ đồ kiến trúc tổng thể của hệ thống

Hệ thống được xây dựng theo mô hình Client–Server và được tổ chức thành năm tầng chính gồm Frontend, Backend, Core Engine, Offline Processing và Database. Việc phân chia thành các tầng giúp tách biệt giao diện, xử lý nghiệp vụ, thực hiện thuật toán và lưu trữ dữ liệu, từ đó thuận lợi cho quá trình bảo trì và mở rộng hệ thống.



Hình 2.2 Sơ đồ kiến trúc tổng thể hệ thống

Tầng Frontend được xây dựng bằng ReactJS kết hợp Tailwind CSS. Đây là thành phần giao tiếp trực tiếp với người dùng, cung cấp các chức năng như tìm kiếm điểm đến, sử dụng bộ lọc, nhập truy vấn bằng ngôn ngữ tự nhiên, xem bản đồ, xem chi tiết điểm đến, đánh giá và quản lý tài khoản. Các yêu cầu từ Frontend được gửi đến Backend thông qua REST API dưới định dạng JSON.

Tầng Backend được phát triển bằng FastAPI và đóng vai trò điều phối hoạt động của hệ thống. Backend tiếp nhận yêu cầu từ Frontend, kiểm tra dữ liệu đầu vào, xác thực người dùng, truy xuất cơ sở dữ liệu và gọi các thành phần xử lý phù hợp. Đối với truy vấn ngôn ngữ tự nhiên, Backend gửi nội dung đến Gemini API để trích xuất các tiêu chí cần thiết trước khi chuyển đến mô hình gợi ý.

Tầng Core Engine là thành phần thực hiện quá trình lọc, tính điểm và xếp hạng điểm đến. Content-Based Filtering đánh giá mức độ phù hợp giữa yêu cầu người dùng và đặc trưng của điểm đến. Thành phần Apriori đọc các luật đã khai phá từ cơ sở dữ liệu để bổ sung điểm dựa trên các mối quan hệ giữa mùa, ngân sách, loại hình và khu vực địa lý. Collaborative Filtering sử dụng dữ liệu đánh giá hoặc lịch sử tương tác để tăng mức độ cá nhân hóa cho người dùng đã có dữ liệu sử dụng.

Các thành phần trên được tổng hợp trong Hybrid Recommender để tạo điểm cuối cùng và lựa chọn danh sách điểm đến phù hợp. Thuật toán K-Means không trực tiếp tham gia vào công thức tính điểm cuối cùng mà được sử dụng để xác định các điểm đến tương đồng, hỗ trợ đề xuất địa điểm thay thế.

Tầng Offline Processing thực hiện các tác vụ không cần chạy lại mỗi khi người dùng gửi yêu cầu. Dữ liệu sau khi được làm sạch và chuẩn hóa được sử dụng để khai phá luật kết hợp bằng Apriori, phân cụm bằng K-Means và chuẩn bị các cấu trúc dữ liệu cần thiết cho mô hình gợi ý. Các tiến trình này được chạy định kỳ hoặc khi dữ liệu được cập nhật.

Tầng Database sử dụng MongoDB làm nơi lưu trữ trung tâm. Cơ sở dữ liệu lưu thông tin điểm đến, người dùng, đánh giá, lịch sử tương tác, luật kết hợp Apriori và nhãn phân cụm K-Means. Kết quả từ tầng Offline Processing được ghi vào MongoDB, sau đó Core Engine truy xuất lại khi có yêu cầu gợi ý trong thời gian thực.

Bên cạnh các tầng chính, hệ thống kết nối với một số dịch vụ bên ngoài. Gemini API hỗ trợ phân tích truy vấn và sinh phản hồi tự nhiên; OpenStreetMap và các dịch vụ geocoding cung cấp dữ liệu bản đồ và tọa độ địa lý. Các dịch vụ này chỉ bổ sung thông tin cho hệ thống, không thay thế cơ chế tính điểm của Hybrid Recommender.

Quy trình xử lý tổng quát của kiến trúc gồm các bước: người dùng gửi yêu cầu từ Frontend; Backend tiếp nhận và chuẩn hóa dữ liệu; Gemini được gọi khi yêu cầu ở dạng ngôn ngữ tự nhiên; Core Engine tính các thành phần điểm; Hybrid Recommender tổng hợp và xếp hạng; Backend truy xuất thêm thông tin điểm đến; kết quả cuối cùng được trả về Frontend để hiển thị.

Kiến trúc phân tầng giúp tách các tác vụ xử lý ngoại tuyến khỏi luồng phản hồi thời gian thực. Nhờ đó, những thuật toán có chi phí tính toán lớn như Apriori và K-Means không cần thực hiện lại cho mỗi yêu cầu, góp phần giảm thời gian phản hồi của hệ thống.

2.6.4 Frontend

2.6.4.1 ReactJS

ReactJS là thư viện xây dựng giao diện theo component [27], còn Tailwind CSS cung cấp các lớp tiện ích để thiết kế nhanh và hỗ trợ responsive [33]. Trong đề tài, hai công nghệ này được dùng để xây dựng trang chủ, danh sách điểm đến, trang gợi ý, chatbot và dashboard quản trị.

Khởi tạo và chạy dự án:

```
npm create vite@latest
```

```
npm install
```

```
npm run dev
```

Ưu điểm: giao diện dễ tái sử dụng, cập nhật nhanh và thuận lợi khi phát triển ứng dụng trang đơn. Hạn chế: dự án có thể phụ thuộc nhiều gói npm và cần tổ chức component hợp lý để tránh mã nguồn phức tạp.

2.6.4.2 Tailwind CSS

Tailwind CSS là một framework CSS ưu tiên tiện ích, cung cấp các lớp cấp thấp như flex, pt-4, text-center và rotate-90 để xây dựng giao diện tùy chỉnh ngay trong tệp markup (HTML/JSEX) [32].

Lệnh cài đặt:

```
npm install -D tailwindcss postcss autoprefixer
```

```
npx tailwindcss init -p
```

Lợi ích: Không cần viết CSS thủ công: Giảm thiểu việc phải đặt tên class và chuyển đổi qua lại giữa các file .css và .js. Tối ưu dung lượng: Khi xây dựng, Tailwind tự động loại bỏ các class không sử dụng, giúp file CSS cuối cùng cực nhẹ. Responsive dễ dàng: Hỗ trợ tiền tố (như md:, lg:) để thiết kế giao diện đáp ứng nhanh chóng.

2.6.5 Cơ sở dữ liệu – MongoDB

MongoDB là hệ quản trị cơ sở dữ liệu NoSQL lưu dữ liệu dưới dạng tài liệu BSON, phù hợp với dữ liệu bán cấu trúc và thay đổi linh hoạt [18]. PyMongo là thư viện kết nối MongoDB với Python [19]. Trong hệ thống, MongoDB lưu thông tin điểm đến, người dùng, đánh giá, luật Apriori, nhãn K-Means và lịch sử tương tác.

Cài đặt thư viện kết nối:

```
pip install pymongo
```

Ưu điểm: schema linh hoạt, dễ mở rộng và phù hợp dữ liệu JSON. Hạn chế: cần thiết kế chỉ mục và kiểm soát tính nhất quán; các quan hệ phức tạp không thuận tiện như cơ sở dữ liệu quan hệ.

2.6.6 Thư viện bản đồ – Leaflet.js

Leaflet.js là thư viện JavaScript mã nguồn mở được sử dụng để xây dựng bản đồ tương tác trên nền tảng web. Thư viện có kích thước nhẹ và hỗ trợ nhiều chức năng như điểm đánh dấu, lớp bản đồ, cửa sổ thông tin và các sự kiện tương tác [14].

Trong đề tài, Leaflet.js được kết hợp với React-Leaflet để hiển thị bản đồ thế giới, xác định vị trí các điểm đến theo tọa độ, hiển thị điểm đánh dấu và cung cấp thông tin tóm tắt khi người dùng lựa chọn một địa điểm. Bản đồ cũng được liên kết với trang chi tiết để người dùng có thể truy cập thông tin đầy đủ của từng điểm đến.

Dữ liệu nền bản đồ được lấy từ OpenStreetMap [22]. Các thư viện cần thiết được cài đặt bằng lệnh:

```
npm install leaflet react-leaflet
```

Leaflet.js chỉ đảm nhiệm chức năng trực quan hóa vị trí. Quá trình lựa chọn, tính điểm và xếp hạng điểm đến vẫn được thực hiện bởi Backend và mô hình gợi ý.

2.6.7 Nguồn dữ liệu

Dữ liệu của hệ thống được tổng hợp từ nhiều nguồn nhằm bổ sung thông tin về điểm đến, quốc gia, tọa độ và các thuộc tính phục vụ quá trình gợi ý.

Bộ dữ liệu Tourist Destinations Dataset trên nền tảng Kaggle cung cấp các trường thông tin cơ bản như tên điểm đến, quốc gia, loại hình du lịch, mùa phù hợp, chi phí và mức đánh giá. Đây là nguồn dữ liệu nền tảng được sử dụng trong hệ thống [13].

REST Countries API cung cấp các thông tin liên quan đến quốc gia như tên chính thức, thủ đô, khu vực, mã quốc gia, ngôn ngữ và tiền tệ [28]. Các thông tin này được sử dụng để bổ sung và chuẩn hóa dữ liệu quốc gia trong tập dữ liệu chính.

OpenStreetMap cung cấp dữ liệu bản đồ mở, trong khi Nominatim hỗ trợ chuyển đổi tên địa điểm thành tọa độ địa lý. Các tọa độ sau khi thu thập được sử dụng để xác định vị trí và hiển thị điểm đến trên bản đồ tương tác [20], [22].

Public Holidays API cung cấp thông tin về các ngày lễ theo từng quốc gia [24]. Nguồn dữ liệu này có thể được sử dụng để bổ sung ngữ cảnh thời gian và hỗ trợ mở rộng chức năng gợi ý theo các dịp lễ trong tương lai.

Do dữ liệu được thu thập từ nhiều nguồn nên có thể khác nhau về cấu trúc, định dạng và mức độ đầy đủ. Vì vậy, dữ liệu cần được làm sạch, chuẩn hóa và kiểm tra trước khi đưa vào các thuật toán khai phá dữ liệu và mô hình gợi ý.

2.6.8 Thư viện Python sử dụng trong hệ thống

Bên cạnh FastAPI và PyMongo, hệ thống sử dụng nhiều thư viện Python phục vụ các nhiệm vụ xử lý dữ liệu, khai phá luật kết hợp, phân cụm và xây dựng mô hình gợi ý.

Pandas được sử dụng để đọc dữ liệu từ các tệp CSV, làm sạch giá trị thiếu, loại bỏ dữ liệu trùng lặp, chuyển đổi kiểu dữ liệu và thực hiện các thống kê mô tả. NumPy hỗ trợ tính toán số học, xử lý mảng và các phép toán trên vector hoặc ma trận [21], [23].

Thư viện mlxtend cung cấp các hàm apriori() và association_rules() để tìm tập mục phổ biến và sinh luật kết hợp. Kết quả thu được bao gồm các độ đo như Support, Confidence và Lift, được sử dụng để lựa chọn các luật có ý nghĩa [26].

Scikit-learn cung cấp các công cụ phục vụ nhiều thành phần của hệ thống. Thuật toán K-Means được dùng để phân cụm điểm đến, StandardScaler được sử dụng để chuẩn hóa đặc trưng số, TF-IDF Vectorizer chuyển đổi dữ liệu văn bản thành vector và Cosine Similarity được dùng để tính mức độ tương đồng [31], [32].

GeoPandas hỗ trợ xử lý dữ liệu không gian, trong khi Geopy và Nominatim được sử dụng để chuyển đổi tên địa điểm thành tọa độ. PyMongo hỗ trợ đọc và ghi dữ liệu từ MongoDB. Thư viện google-genai được dùng để gửi truy vấn và nhận kết quả từ Gemini API.

Các thư viện cần thiết có thể được cài đặt bằng lệnh:

```
pip install pandas numpy mlxtend scikit-learn  
geopandas geopy pymongo google-genai
```

CHƯƠNG 3. HIỆN THỰC HÓA NGHIÊN CỨU

3.1 Mô tả bài toán

Trong lĩnh vực du lịch, người dùng thường phải lựa chọn điểm đến từ số lượng lớn địa danh với nhiều thông tin khác nhau về mùa du lịch, chi phí, loại hình trải nghiệm, vị trí địa lý và đánh giá của cộng đồng. Khi dữ liệu ngày càng đa dạng, việc tìm kiếm và so sánh thủ công trở nên mất nhiều thời gian, đồng thời khó bảo đảm điểm đến được lựa chọn phù hợp với nhu cầu cá nhân.

Đề tài xây dựng hệ thống gợi ý điểm du lịch quốc tế theo mô hình Hybrid Recommendation, kết hợp Content-Based Filtering, luật kết hợp Apriori và Collaborative Filtering nhằm tận dụng ưu điểm của từng phương pháp trong quá trình tính điểm và xếp hạng điểm đến [1], [10], [12], [29]. Bên cạnh đó, Gemini API được tích hợp để phân tích truy vấn bằng ngôn ngữ tự nhiên, giúp người dùng có thể nhập yêu cầu dưới dạng câu hỏi thay vì chỉ sử dụng các bộ lọc cố định [7].

Bài toán được xác định trên tập dữ liệu du lịch quốc tế (D), trong đó mỗi điểm đến được mô tả bởi các thuộc tính như tên điểm đến, quốc gia, châu lục, mùa phù hợp, loại hình du lịch, mức chi phí, đánh giá, tọa độ địa lý và các thông tin liên quan. Từ tập dữ liệu này, hệ thống thực hiện khai phá luật kết hợp bằng Apriori và phân cụm điểm đến bằng K-Means để tạo nguồn tri thức hỗ trợ gợi ý.

Ký hiệu tập dữ liệu điểm đến được sử dụng trong bài toán như sau:

$$D = \{d_1, d_2, \dots, d_m\}$$

Trong đó:

- D là tập dữ liệu điểm đến;
- d_i là điểm đến thứ i ;
- m là tổng số điểm đến trong tập dữ liệu.

Khi sử dụng hệ thống, người dùng cung cấp tập điều kiện đầu vào (Q), có thể gồm mùa du lịch, ngân sách, loại hình trải nghiệm, quốc gia, châu lục hoặc một truy vấn bằng ngôn ngữ tự nhiên.

Tập điều kiện đầu vào được biểu diễn như sau:

$$Q = \{season, budget, type, country, continent, query\}$$

Trong đó:

- (season) là mùa du lịch;
- (budget) là mức ngân sách;
- (type) là loại hình du lịch;
- (country) là quốc gia;
- (continent) là châu lục;
- (query) là nội dung truy vấn bằng ngôn ngữ tự nhiên.

Hai biểu thức trên chỉ dùng để mô tả hình thức đầu vào của bài toán, không phải công thức được kế thừa từ một thuật toán cụ thể.

Từ tập điều kiện (Q), hệ thống chuẩn hóa dữ liệu đầu vào, lọc các điểm đến phù hợp và tính điểm cho từng điểm đến bằng mô hình Hybrid Recommendation. Sau đó, hệ thống sắp xếp kết quả theo thứ tự giảm dần và trả về danh sách (Top\text{-}N) điểm đến có điểm số cao nhất.

Danh sách kết quả được biểu diễn như sau:

$$R_{Top-N} = \{d_{(1)}, d_{(2)}, \dots, d_{(N)}\}$$

Trong đó:


- R_{Top-N} là danh sách kết quả gợi ý;
- $d_{(1)}$ là điểm đến có điểm xếp hạng cao nhất;
- $d_{(N)}$ là điểm đến đứng ở vị trí thứ (N);
- N là số lượng điểm đến được trả về.

Ngoài danh sách điểm đến, hệ thống còn cung cấp các thông tin hỗ trợ như điểm phù hợp, thuộc tính nổi bật, lý do được gợi ý và vị trí trên bản đồ. Với người dùng đã có lịch sử đánh giá, kết quả có thể được bổ sung tín hiệu từ Collaborative Filtering để tăng mức độ cá nhân hóa.

Như vậy, mục tiêu của bài toán là xây dựng một hệ thống có khả năng tiếp nhận nhiều dạng yêu cầu, khai thác dữ liệu và tri thức từ các thuật toán, sau đó trả về danh sách điểm đến phù hợp, có thứ tự xếp hạng và có thể giải thích được.

3.2 Kiến trúc tổng thể hệ thống

Sơ đồ luồng xử lý dữ liệu mô tả quá trình từ khi dữ liệu được thu thập cho đến khi hệ thống trả kết quả gợi ý cho người dùng. Quy trình được chia thành hai nhóm chính gồm xử lý ngoại tuyến và xử lý thời gian thực.



Hình 3.1 Sơ đồ luồng xử lý dữ liệu

Giai đoạn xử lý ngoại tuyến, dữ liệu được thu thập từ các bộ dữ liệu công khai và các API mở. Dữ liệu thô sau đó được làm sạch, loại bỏ bản ghi trùng lặp, xử lý giá trị thiếu, chuẩn hóa tên quốc gia, tọa độ, mùa, loại hình du lịch và mức chi phí.

Sau khi hoàn tất quá trình tiền xử lý, dữ liệu được chuyển đổi theo yêu cầu của từng thuật toán. Đối với Apriori, các thuộc tính phân loại được mã hóa thành ma trận giao dịch nhị phân để khai phá tập mục phổ biến và sinh luật kết hợp. Đối với K-Means, các thuộc tính số được lựa chọn và chuẩn hóa trước khi tiến hành phân cụm.

Kết quả của giai đoạn ngoại tuyến gồm tập dữ liệu điểm đến đã chuẩn hóa, tập luật kết hợp Apriori và nhãn phân cụm K-Means. Các kết quả này được lưu vào MongoDB để sử dụng trong quá trình vận hành hệ thống.

Ở giai đoạn xử lý thời gian thực, người dùng gửi yêu cầu thông qua bộ lọc, thanh tìm kiếm hoặc chatbot. Nếu người dùng lựa chọn các tiêu chí trực tiếp trên giao diện, Backend tiếp nhận và chuẩn hóa các giá trị đầu vào. Nếu người dùng nhập câu hỏi tự nhiên, nội dung được gửi đến Gemini API để trích xuất các tiêu chí như mùa, ngân sách, loại hình, quốc gia và châu lục.

Khi có tập dữ liệu đã chuẩn hóa, hệ thống áp dụng cơ chế lọc để xác định danh sách điểm đến. Content-Based Filtering tính mức độ phù hợp giữa yêu cầu và đặc trưng điểm đến; luật Apriori phù hợp được truy xuất để bổ sung điểm; Collaborative Filtering cung cấp tín hiệu cá nhân hóa khi người dùng có lịch sử đánh giá.

Hybrid Recommender tổng hợp các thành phần điểm và sắp xếp các điểm đến theo thứ tự giảm dần. Trong trường hợp số lượng ứng viên không đủ, cơ chế Soft Filtering có thể lần lượt nói lỏng một số điều kiện để mở rộng tập kết quả nhưng vẫn duy trì các tiêu chí quan trọng của người dùng.

Sau khi hoàn thành quá trình xếp hạng, Backend lấy thông tin chi tiết của các điểm đến như tên, quốc gia, hình ảnh, chi phí, mức đánh giá, tọa độ và mô tả. Danh sách kết quả được trả về Frontend để hiển thị dưới dạng thẻ điểm đến, danh sách xếp hạng hoặc vị trí trên bản đồ.

Các thao tác đánh giá hoặc tương tác mới của người dùng được lưu trữ lại MongoDB. Dữ liệu này có thể được sử dụng để cập nhật Collaborative Filtering và cải thiện mức độ cá nhân hóa trong các lần gợi ý tiếp theo.

Việc phân chia rõ luồng xử lý ngoại tuyến và thời gian thực giúp hệ thống tránh thực hiện lại các thuật toán khai phá dữ liệu có chi phí lớn trong mỗi yêu cầu. Qua đó, hệ thống vừa duy trì được nguồn tri thức đã khai phá vừa bảo đảm tốc độ phản hồi khi người dùng thao tác.

3.3 Thu thập dữ liệu và xử lý dữ liệu

Dữ liệu là thành phần quan trọng quyết định chất lượng của các thuật toán khai phá dữ liệu và hệ thống gợi ý. Trong đề tài, dữ liệu được thu thập từ nhiều nguồn

khác nhau nhằm cung cấp thông tin về điểm đến, mức chi phí, loại hình du lịch, đánh giá, ngày lễ và vị trí địa lý.

Do các nguồn dữ liệu có cấu trúc, kiểu dữ liệu và cách biểu diễn khác nhau, dữ liệu không được sử dụng trực tiếp mà phải trải qua quá trình làm sạch, chuẩn hóa, tích hợp và chuyển đổi. Kết quả sau xử lý được tổ chức thành các tập dữ liệu riêng, phù hợp với yêu cầu đầu vào của Apriori, K-Means và Content-Based Filtering.

3.3.1 Nguồn, quy mô dữ liệu thô và schema dữ liệu sau khi chuẩn hóa

Nguồn dữ liệu chính của hệ thống là tệp Tourist_Destinations.csv được thu thập từ nền tảng Kaggle. Tập dữ liệu gồm 2.000 bản ghi và 9 thuộc tính, cung cấp các thông tin như tên điểm đến, quốc gia, châu lục, loại hình du lịch, mùa phù hợp, chi phí trung bình, điểm đánh giá, lượng khách tham quan và thông tin di sản. Dữ liệu này được sử dụng để xây dựng danh sách điểm đến, gán nhãn đặc trưng, thực hiện Content-Based Filtering và chuẩn bị dữ liệu cho K-Means.

Tập raw_data_India.csv gồm 7.856 bản ghi và 10 thuộc tính, cung cấp thông tin về các điểm tham quan, vị trí, điểm đánh giá và số lượng nhận xét. Dữ liệu này được sử dụng để bổ sung thông tin về các địa điểm du lịch và hỗ trợ mở rộng tập điểm đến.

Tập Global_Holidays_2025_2035.csv gồm 10.540 bản ghi và 7 thuộc tính, chứa thông tin về ngày lễ của các quốc gia trong giai đoạn từ năm 2025 đến năm 2035. Dữ liệu ngày lễ được sử dụng để bổ sung yếu tố thời gian và làm cơ sở mở rộng chức năng gợi ý hành trình theo dịp lễ.

Dữ liệu trong tệp reviews.csv chứa các đánh giá và lịch sử tương tác được sử dụng để xây dựng dữ liệu cho Collaborative Filtering và ma trận giao dịch phục vụ thuật toán Apriori. Bên cạnh đó, đề tài bổ sung 108 điểm đến được tổng hợp thủ công nhằm tăng độ bao phủ cho tập dữ liệu.

OpenStreetMap và Nominatim được sử dụng để bổ sung tọa độ địa lý và thông tin vị trí. Dữ liệu tọa độ được dùng để hiển thị điểm đến trên bản đồ và hỗ trợ chức năng tìm kiếm địa điểm.

Sau khi thu thập, các trường dữ liệu được đổi tên, chuyển đổi kiểu và tổ chức lại theo một schema thống nhất trước khi lưu vào MongoDB.

Bảng 3.1 Bảng dữ liệu thô được chuẩn hóa và tổ chức lại theo schema thống nhất

Trường	Kiểu dữ liệu	Ý nghĩa
destination_id	String	Mã định danh của điểm đến
name	String	Tên điểm đến
country	String	Quốc gia
continent	String	Châu lục
category	String	Loại hình du lịch ban đầu
broader_type	String	Nhóm loại hình đã chuẩn hóa
best_season	String	Mùa du lịch phù hợp
avg_cost_usd_per_day	Float	Chi phí trung bình mỗi ngày
cost_category	String	Nhóm mức chi phí
cost_of_living_index	Float	Chỉ số mức sống
restaurant_price_index	Float	Chỉ số giá nhà hàng
local_purchasing_power_index	Float	Chỉ số sức mua nội địa
avg_rating	Float	Điểm đánh giá trung bình
latitude, longitude	Float	Tọa độ địa lý
description	String	Nội dung mô tả dùng cho TF-IDF
cluster	Integer	Nhãn cụm K-Means


Schema thống nhất giúp Backend truy xuất dữ liệu thuận tiện, đồng thời bảo đảm các thuật toán sử dụng cùng cách đặt tên và biểu diễn thuộc tính.

3.3.2 Quy trình tiền xử lý dữ liệu

Dữ liệu thô tồn tại một số vấn đề như bản ghi trùng lặp, giá trị thiếu, tên thuộc tính không thống nhất và sự khác biệt về đơn vị đo. Vì vậy, đề tài xây dựng quy trình

Xây dựng hệ thống gợi ý điểm du lịch quốc tế dựa trên khai phá dữ liệu

tiền xử lý gồm năm bước: thu thập dữ liệu, làm sạch dữ liệu, chuẩn hóa dữ liệu, tích hợp dữ liệu và chuẩn bị dữ liệu cho từng thuật toán.



Hình 3.2 Quy trình tiền xử lý dữ liệu

Bước 1 – Thu thập dữ liệu: Các tệp dữ liệu gồm Tourist_Destinations.csv, raw_data_India.csv, Global_Holidays_2025_2035.csv và reviews.csv được thu thập và lưu dưới định dạng CSV. Ngoài ra, hệ thống sử dụng OpenStreetMap, Nominatim và 108 điểm đến được tổng hợp bổ sung. Các tệp được đọc bằng thư viện Pandas và lưu trong thư mục dữ liệu thô trước khi thực hiện các thao tác xử lý.

Bước 2 – Làm sạch dữ liệu Quá trình làm sạch tập trung vào việc phát hiện bản ghi trùng lặp, xử lý giá trị thiếu, kiểm tra kiểu dữ liệu và loại bỏ những bản ghi không đáp ứng yêu cầu.

Trong tập Tourist_Destinations.csv, hệ thống phát hiện 743 bản ghi trùng theo cặp thuộc tính tên điểm đến và quốc gia. Sau khi loại bỏ, tập dữ liệu còn 1.257 điểm đến không trùng lặp.

Trong tập raw_data_India.csv, hệ thống kiểm tra bản ghi trùng theo tên điểm tham quan, đồng thời xử lý các hàng thiếu thông tin đánh giá hoặc số lượng nhận xét. Sau quá trình làm sạch, tập dữ liệu còn 6.868 bản ghi và 7 thuộc tính cần thiết.

Các giá trị của thuộc tính avg_rating được kiểm tra trong khoảng từ 1 đến 5, còn avg_cost_usd_per_day phải lớn hơn 0. Kết quả kiểm tra cho thấy sau khi loại bỏ dữ liệu trùng, không có thêm bản ghi nào vi phạm hai điều kiện trên.

Bước 3 – Chuẩn hóa dữ liệu: Sau khi làm sạch, tên thuộc tính và kiểu dữ liệu được chuyển đổi về cùng một định dạng. Tên quốc gia, châu lục, mùa du lịch và loại hình du lịch được chuẩn hóa nhằm hạn chế trường hợp cùng một giá trị nhưng được viết theo nhiều cách khác nhau.

Các giá trị chi phí được quy đổi về đơn vị USD/ngày. Các thuộc tính số như chi phí, điểm đánh giá và chỉ số quốc gia được chuyển sang kiểu số thực. Dữ liệu văn bản được loại bỏ khoảng trắng dư thừa và chuẩn hóa cách viết.

Các loại hình chi tiết tiếp tục được ánh xạ về các nhóm tổng quát như Heritage, Nature, Adventure và Modern. Chi phí được phân thành các mức Budget, Moderate, Expensive và Luxury.

Bước 4 – Tích hợp dữ liệu: Các tập dữ liệu sau chuẩn hóa được kết hợp dựa trên các trường tương ứng như tên điểm đến, quốc gia hoặc mã định danh. Thông tin về điểm đến được bổ sung thêm tọa độ, chỉ số mức sống, nhóm chi phí, ngày lễ và các thuộc tính phục vụ thuật toán.

Việc tích hợp được thực hiện có chọn lọc. Những dữ liệu không liên quan trực tiếp đến một thuật toán không bắt buộc phải ghép vào cùng một bảng. Ví dụ, dữ liệu ngày lễ được lưu riêng để phục vụ chức năng theo thời gian, trong khi các chỉ số mức sống được gắn với dữ liệu dùng cho K-Means.

Bước 5 – Chuẩn bị dữ liệu cho từng thuật toán: Mỗi thuật toán có yêu cầu đầu vào khác nhau nên dữ liệu sau tích hợp được chuyển thành các cấu trúc riêng.

Đối với Apriori, các thuộc tính phân loại được chuyển thành ma trận giao dịch nhị phân bằng One-Hot Encoding. Đối với K-Means, bốn đặc trưng số liên quan đến mức chi phí được xử lý giá trị thiếu và chuẩn hóa bằng StandardScaler. Đối với Content-Based Filtering, các thuộc tính văn bản được ghép thành chuỗi đặc trưng và biểu diễn bằng TF-IDF.

Kết quả sau xử lý được lưu dưới dạng tệp trung gian hoặc trong MongoDB để sử dụng trong quá trình khai phá dữ liệu và gợi ý thời gian thực.

3.3.3 Thống kê mô tả dữ liệu thô và kết quả tiền xử lý

3.3.3.1 Quy mô các nguồn dữ liệu thô

Hệ thống thu thập dữ liệu thô từ ba nguồn độc lập, với quy mô cụ thể như sau:

Bảng 3.2 Dữ liệu thô

Nguồn dữ liệu	Số dòng	Số cột	Nội dung
Tourist_Destinations.csv	2.000	9	Thông tin điểm đến, chi phí, mùa, đánh giá và lượt khách

Xây dựng hệ thống gợi ý điểm du lịch quốc tế dựa trên khai phá dữ liệu

Nguồn dữ liệu	Số dòng	Số cột	Nội dung
raw_data_India.csv	7.856	10	Thông tin các điểm tham quan
Global_Holidays_2025_2035.csv	10.540	7	Ngày lễ theo quốc gia
Ma trận giao dịch Apriori	10.050	95	Giao dịch và các item du lịch đã mã hóa

Các tập dữ liệu có quy mô và cấu trúc khác nhau. Do đó, việc đánh giá dữ liệu thô là cần thiết trước khi quyết định phương pháp làm sạch và chuyển đổi.

3.3.3.2 Thống kê mô tả các biến số trên tập điểm đến gốc

Trên tập Tourist_Destinations.csv (2.000 dòng), ba biến số liên tục có phân bố như sau:

Bảng 3.3 Các biến số trên tập điểm đến gốc

Biến	Trung bình	Độ lệch chuẩn	Min	Trung vị	Max
Avg Cost (USD/day)	148,27	48,93	30,00	148,64	303,84
Avg Rating	4,49	0,29	3,50	4,50	5,00
Annual Visitors (M)	5,18	2,75	0,50	5,24	10,00

Điểm đánh giá tập trung trong khoảng tương đối hẹp quanh giá trị 4,5, trong khi chi phí có mức phân tán lớn hơn, từ 30 USD đến hơn 300 USD mỗi ngày. Sự khác biệt về miền giá trị cho thấy các thuộc tính số cần được chuẩn hóa trước khi tính khoảng cách trong K-Means.

3.3.3.3 Kiểm tra chất lượng dữ liệu thô

Tập Tourist_Destinations.csv không có giá trị thiếu nhưng tồn tại 743 bản ghi trùng theo tên điểm đến và quốc gia. Tập raw_data_India.csv thiếu dữ liệu tại các trường place_id, link, reviews và rating. Một số trường không cần thiết được loại bỏ trước khi tích hợp.

Trong tập dữ liệu ngày lễ, trường Local_Name thiếu toàn bộ giá trị và trường Description thiếu một tỷ lệ nhỏ. Trường Local_Name không được sử dụng trong hệ

Xây dựng hệ thống gợi ý điểm du lịch quốc tế dựa trên khai phá dữ liệu

thống, còn các giá trị mô tả thiếu được thay thế hoặc để trống tùy theo chức năng sử dụng.

3.3.3.4 Kết quả sau làm sạch và tiền xử lý

Sau khi loại bỏ dữ liệu trùng, tập điểm đến chính giảm từ 2.000 xuống còn 1.257 bản ghi không trùng lặp. Tập 1.257 bản ghi được sử dụng để thống kê phân bố chi phí, loại hình và phục vụ các chức năng tra cứu điểm đến.

Trong số 1.257 điểm đến, có 359 bản ghi chứa đầy đủ hoặc có thể bổ sung đầy đủ bốn đặc trưng số cần thiết cho K-Means. Vì vậy, tập K-Means gồm 359 điểm đến, không phải toàn bộ 1.257 điểm đến.

Bảng 3.4 Kết quả sau khi làm sạch và tiền xử lý dữ liệu

Tập dữ liệu	Trước xử lý	Sau xử lý	Mục đích sử dụng
Tập điểm đến không trùng	2.000 dòng $\times$ 9 cột	1.257 dòng	Tra cứu, thống kê và Content-Based Filtering
Tập điểm đến dùng cho K-Means	1.257 dòng	359 dòng $\times$ các đặc trưng cần thiết	Phân cụm điểm đến
Tập POI	7.856 dòng $\times$ 10 cột	6.868 dòng $\times$ 7 cột	Bổ sung thông tin điểm tham quan
Tập ngày lễ	10.540 dòng $\times$ 7 cột	10.540 dòng $\times$ 9 cột	Bổ sung tháng và mùa của ngày lễ
Ma trận giao dịch Apriori	Dữ liệu đánh giá và thuộc tính	10.050 dòng $\times$ 95 cột	Khai phá luật kết hợp

Sau khi gán nhãn mức chi phí trên 1.257 điểm đến, nhóm Expensive gồm 585 điểm đến, nhóm Moderate gồm 518 điểm đến, nhóm Budget gồm 115 điểm đến và nhóm Luxury gồm 39 điểm đến.

Theo nhóm loại hình tổng quát, Heritage gồm 424 điểm đến, Nature gồm 405 điểm đến, Adventure gồm 222 điểm đến và Modern gồm 206 điểm đến.

Kết quả phân bố trên được sử dụng để mô tả dữ liệu sau tiền xử lý. Kết quả chạy thuật toán K-Means và đặc trưng của từng cụm.

3.3.4 Quy trình mã hóa giao dịch bằng ma trận nhị phân cho Apriori

Thuật toán Apriori yêu cầu dữ liệu đầu vào ở dạng giao dịch nhị phân. Trong đề tài, mỗi giao dịch đại diện cho một bản ghi tương tác, đánh giá hoặc tổ hợp tiêu chí du lịch được hình thành từ dữ liệu người dùng và các thuộc tính liên quan.

Một giao dịch có thể chứa các item như Season: Summer, Cost: Budget, Type: Cultural, Country: Japan hoặc Continent: Asia. Mỗi giá trị thuộc tính được chuyển thành một cột riêng trong ma trận giao dịch bằng phương pháp One-Hot Encoding [26].

Theo nguyên lý One-Hot Encoding [26], giá trị tại hàng (i), cột (j) được biểu diễn như sau:

$$x_{ij} = \begin{cases} 1, & \text{nếu item } j \text{ xuất hiện trong giao dịch } i \\ 0, & \text{nếu item } j \text{ không xuất hiện trong giao dịch } i \end{cases}$$

Trong đó, x_{ij} là giá trị tại giao dịch thứ (i) và item thứ (j). Giá trị 1 biểu thị item xuất hiện trong giao dịch, còn giá trị 0 biểu thị item không xuất hiện.

Sau khi mã hóa, ma trận giao dịch của đề tài gồm 10.050 giao dịch và 95 item. Các item thuộc những nhóm như mùa, mức chi phí, loại hình du lịch, quốc gia, châu lục và một số đặc trưng liên quan.

Cách biểu diễn này cho phép Apriori xác định các tập mục phổ biến và khai phá mối liên hệ giữa các tiêu chí du lịch. Các luật thu được được lưu vào MongoDB. Khi yêu cầu của người dùng khớp với vế trái của một luật, các điểm đến thỏa mãn vế phải có thể được cộng điểm Apriori trong quá trình xếp hạng.

3.3.5 Quy trình chuẩn hóa đặc trưng số cho K-Means

K-Means sử dụng khoảng cách Euclidean nên kết quả có thể bị chi phối bởi những thuộc tính có miền giá trị lớn. Vì vậy, các đặc trưng số cần được đưa về cùng thang đo trước khi phân cụm.

Trong đề tài, bốn đặc trưng được lựa chọn gồm:

- Chi phí trung bình mỗi ngày;
- Chỉ số mức sống;
- Chỉ số giá nhà hàng;
- Chỉ số sức mua nội địa.

Bốn đặc trưng trên cùng phản ánh mức độ đắt đỏ và khả năng chi trả tại điểm đến. Điểm đánh giá có thể được sử dụng để trực quan hóa hoặc mô tả các cụm nhưng không phải là một trong bốn đặc trưng chính dùng để huấn luyện K-Means.

Các giá trị thiếu của từng đặc trưng được thay thế bằng giá trị trung vị. Cách sử dụng trung vị giúp hạn chế ảnh hưởng của các giá trị ngoại lai trong dữ liệu chi phí.

Sau đó, dữ liệu được chuẩn hóa bằng StandardScaler của thư viện scikit-learn. Giá trị chuẩn hóa của thuộc tính được xác định bằng công thức [31]:

$$z_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}$$

Trong đó:

- x_{ij} là giá trị ban đầu của đối tượng (i) tại thuộc tính (j);
- μ_j là giá trị trung bình của thuộc tính (j);
- σ_j là độ lệch chuẩn của thuộc tính (j);
- z_{ij} là giá trị sau chuẩn hóa.

Sau khi chuẩn hóa, mỗi thuộc tính có trung bình xấp xỉ 0 và độ lệch chuẩn xấp xỉ 1. Nhờ đó, các đặc trưng có mức độ ảnh hưởng cân bằng hơn trong quá trình tính khoảng cách.

Tập dữ liệu gồm 359 điểm đến được đưa vào K-Means với số cụm (K=5). Mỗi điểm đến được gán một nhãn cụm từ 0 đến 4. Sau đó, hệ thống tính chi phí trung bình của từng cụm để diễn giải các cụm theo các mức chi phí tương ứng.

Kết quả phân cụm được lưu vào MongoDB và sử dụng để tìm các điểm đến tương tự theo mức chi phí. Nhãn K-Means không trực tiếp tham gia vào công thức tính Score_final của mô hình Hybrid Recommendation.

3.4 Thiết kế hệ thống

3.4.1 Thiết kế thuật toán Hybrid Recommender

Hệ thống được thiết kế theo mô hình Hybrid Recommendation, kết hợp ba thành phần gồm Content-Based Filtering, luật kết hợp Apriori và Collaborative Filtering. Mỗi thành phần đảm nhiệm một vai trò riêng trong quá trình đánh giá và xếp hạng điểm đến.

Khi người dùng gửi yêu cầu, hệ thống phân tích dữ liệu đầu vào để xác định các tiêu chí như mùa du lịch, mức ngân sách, loại hình trải nghiệm, quốc gia và châu lục. Nếu yêu cầu được nhập bằng ngôn ngữ tự nhiên, Gemini API hỗ trợ trích xuất các tiêu chí và chuyển chúng về cấu trúc thống nhất trước khi đưa vào mô hình gợi ý.

Content-Based Filtering được sử dụng để tính mức độ tương đồng giữa yêu cầu người dùng và đặc trưng của từng điểm đến. Các luật Apriori cung cấp tri thức khai phá từ dữ liệu để bổ sung điểm ưu tiên. Collaborative Filtering tạo điểm thưởng cho các điểm đến phù hợp với lịch sử đánh giá của người dùng đã đăng nhập.

Sau khi tính các thành phần điểm, hệ thống tổng hợp chúng thành điểm cuối cùng, sắp xếp các điểm đến theo thứ tự giảm dần và trả về danh sách Top-N. Thuật toán K-Means không trực tiếp tham gia vào công thức tính điểm Hybrid mà được sử dụng để tìm các điểm đến tương tự thuộc cùng cụm.

3.4.1.1 Quy trình xử lý của mô hình Hybrid Recommendation

Quy trình gợi ý được thực hiện qua các bước sau:

Bước 1 – Tiếp nhận yêu cầu: Hệ thống nhận các tiêu chí được lựa chọn trên giao diện hoặc câu truy vấn bằng ngôn ngữ tự nhiên.

Bước 2 – Chuẩn hóa đầu vào: Các giá trị về mùa, ngân sách, loại hình, quốc gia và châu lục được chuyển về cùng cách biểu diễn với dữ liệu trong cơ sở dữ liệu.

Bước 3 – Xác định tập ứng viên: Hệ thống lọc các điểm đến đáp ứng các điều kiện ban đầu. Nếu số lượng kết quả không đủ, cơ chế Soft Filtering được sử dụng để mở rộng tập ứng viên.

Bước 4 – Tính điểm nội dung: Yêu cầu của người dùng và dữ liệu điểm đến được biểu diễn bằng TF-IDF, sau đó tính độ tương đồng bằng Cosine Similarity.

Bước 5 – Tính điểm Apriori: Hệ thống tìm các luật có vế trái phù hợp với yêu cầu người dùng và xác định mức ưu tiên cho từng điểm đến dựa trên vế phải của luật.

Bước 6 – Tính điểm Collaborative Filtering: Đối với người dùng đã có lịch sử đánh giá, hệ thống kiểm tra xem điểm đến đang xét có thuộc danh sách gợi ý cộng tác hay không.

Bước 7 – Tổng hợp và xếp hạng: Các thành phần điểm được kết hợp để tạo điểm cuối cùng. Hệ thống sắp xếp kết quả theo thứ tự giảm dần và trả về Top-N điểm đến.

3.4.1.2 Công thức tính điểm tổng hợp

Dựa trên nguyên lý kết hợp có trọng số của hệ thống gợi ý lai [11], [12], [29], đề xuất hai trường hợp tính điểm cuối cùng.

Trường hợp 1: Có ít nhất một luật Apriori phù hợp

Khi yêu cầu của người dùng khớp với một hoặc nhiều luật kết hợp, điểm cuối cùng được xác định bằng công thức:

$$Score_{final} = 0,6 \times Score_{content} + 0,4 \times Score_{apriori} + Boost_{CF}$$

(Nguồn: Tác giả đề xuất.)

Trường hợp 2: Không tìm thấy luật Apriori phù hợp

Khi không có luật phù hợp, hệ thống không đưa thành phần Apriori vào công thức nhằm tránh làm giảm điểm của những điểm đến có mức độ tương đồng nội dung cao:

$$Score_{final} = Score_{content} + Boost_{CF}$$

(Nguồn: Tác giả đề xuất.)

Trong đó, $Score_{content}$ là điểm tương đồng nội dung; $Score_{apriori}$ là điểm ưu tiên từ luật kết hợp; $Boost_{CF}$ là điểm thưởng từ Collaborative Filtering.

Hai trọng số của Content-Based Filtering và Apriori thỏa mãn điều kiện:

$$\alpha + \beta = 1$$

Trong đề tài, việc lựa chọn $\alpha = 0,6$ và $\beta = 0,4$. Content-Based Filtering được đặt trọng số lớn hơn vì phản ánh trực tiếp mức độ phù hợp giữa yêu cầu hiện tại và đặc trưng điểm đến. Apriori giữ vai trò bổ trợ vì chất lượng điểm phụ thuộc vào việc có luật phù hợp với yêu cầu hay không.

Các trọng số 0,6 và 0,4 là giá trị do tác giả lựa chọn dựa trên vai trò của từng thành phần và kết quả kiểm thử thực nghiệm, không phải các hằng số bắt buộc của mô hình Hybrid Recommendation.

3.4.1.3 Tính toán ($Score_{content}$)

($Score_{content}$) phản ánh mức độ tương đồng giữa yêu cầu của người dùng và đặc trưng của điểm đến. Các thuộc tính như tên điểm đến, quốc gia, châu lục, loại

hành du lịch, mùa phù hợp và nội dung mô tả được ghép thành một chuỗi văn bản và biểu diễn bằng TF-IDF.

Yêu cầu của người dùng cũng được chuyển thành vector trong cùng không gian đặc trưng. Theo công thức Cosine Similarity [16], [32], điểm nội dung được xác định như sau:

$$Score_{content} = \frac{d \cdot q}{|d||q|}$$

Trong đó, d là vector TF-IDF của điểm đến; q là vector TF-IDF của truy vấn; $d \cdot q$ là tích vô hướng; $|d|$ và $|q|$ là độ dài của hai vector.

Giá trị ($Score_{content}$) nằm trong khoảng từ 0 đến 1 đối với các vector TF-IDF không âm. Giá trị càng gần 1 thì điểm đến càng phù hợp với yêu cầu của người dùng.

3.4.1.4 Tính toán ($Score_{apriori}$)

($Score_{apriori}$) phản ánh mức độ phù hợp của một điểm đến với các luật kết hợp đã được khai phá. Hệ thống tìm các luật có vẻ trái phù hợp với yêu cầu người dùng, sau đó xác định điểm ưu tiên theo bốn nhóm thuộc tính gồm quốc gia, châu lục, loại hình du lịch và mức chi phí.

Dựa trên nguyên lý kết hợp có trọng số [29] và đặc điểm của bài toán, tác giả đề xuất công thức tính điểm Apriori thô như sau:

$$RawScore = 0,40 \times Country + 0,25 \times Continent + 0,20 \times Type + 0,15 \times Cost$$

(Nguồn: Tác giả đề xuất.)

Trong đó, (Country), (Continent), (Type) và (Cost) là các điểm ưu tiên đã được chuẩn hóa trong khoảng từ 0 đến 1 dựa trên mức độ phù hợp của các luật Apriori.

Trọng số 0,40 được dành cho quốc gia vì đây là tiêu chí cụ thể và có ảnh hưởng lớn đến quyết định lựa chọn điểm đến. Châu lục có trọng số 0,25, hỗ trợ mở rộng kết quả sang các quốc gia có vị trí địa lý tương đồng. Loại hình du lịch có trọng số 0,20 vì phản ánh sở thích trải nghiệm. Mức chi phí có trọng số 0,15 và chủ yếu đóng vai trò điều chỉnh thứ hạng do đã được sử dụng trong bước lọc đầu vào.

Tổng các trọng số bằng 1:

$$0,40 + 0,25 + 0,20 + 0,15 = 1$$

Sau khi tính điểm thô, hệ thống giới hạn giá trị điểm Apriori không vượt quá 1 bằng công thức:

$$Score_{apriori} = \min(RawScore, 1)$$

(Nguồn: Tác giả đề xuất.)

Việc giới hạn giá trị giúp $Score_{apriori}$ duy trì cùng miền giá trị với ($Score_{content}$), tránh trường hợp thành phần Apriori tạo ảnh hưởng quá lớn đến kết quả cuối cùng.

3.4.1.5 Tính toán ($Boost_{CF}$)

Collaborative Filtering được sử dụng để bổ sung tín hiệu cá nhân hóa cho người dùng đã đăng nhập và có lịch sử đánh giá. Hệ thống xây dựng danh sách các điểm đến được dự đoán phù hợp dựa trên dữ liệu tương tác trước đó.

Dựa trên vai trò hỗ trợ của Collaborative Filtering trong mô hình Hybrid [11], [29], điểm thưởng như sau:

$$\begin{aligned} & Boost_{\{CF\}} \\ &= \left[\{cases\} 0, \{15, \&\{khi\ điểm\ đến\ thuộc\ danh\ sách\ gợi\ ý\ của\ CF\} \setminus \right. \\ & \left. \setminus 0, \&\{trong\ các\ trường\ hợp\ còn\ lại\} \right] \{cases\} \end{aligned}$$

(Nguồn: Tác giả đề xuất.)

Giá trị 0,15 chỉ đóng vai trò điều chỉnh thứ hạng. Thành phần này không thay thế điểm nội dung hoặc điểm Apriori. Đối với người dùng mới, chưa đăng nhập hoặc chưa có lịch sử đánh giá, $Boost_{\{CF\}}$ bằng 0.

Do có thêm $Boost_{CF}$, giá trị ($Score_{final}$) có thể lớn hơn 1. Tuy nhiên, điểm này chỉ được sử dụng để so sánh và xếp hạng các điểm đến trong cùng một yêu cầu, không được hiểu là xác suất.

3.4.1.6 Cơ chế Soft Filtering

Bộ lọc chính xác có thể không trả về đủ số lượng điểm đến khi người dùng lựa chọn nhiều tiêu chí cùng lúc. Vì vậy, hệ thống sử dụng cơ chế Soft Filtering để lần lượt nói lỏng các điều kiện ít quan trọng hơn thay vì trả về danh sách trống.

Việc nói lỏng chỉ làm thay đổi tập điểm đến ứng viên, không làm thay đổi công thức tính ($Score_{final}$). Sau mỗi mức nói lỏng, hệ thống tiếp tục tính điểm Hybrid và dừng khi đã thu được đủ số lượng Top-N.

Bảng 3.5 Mô tả các bước nói lỏng của cơ chế Soft Filtering

Mức xử lý	Điều kiện được áp dụng	Mục đích
Mức 0	Giữ toàn bộ mùa, ngân sách, loại hình, quốc gia và châu lục	Tìm kết quả phù hợp chính xác
Mức 1	Nếu không có kết quả tại quốc gia đã chọn, mở rộng sang các điểm đến cùng châu lục	Giữ sự tương đồng về khu vực
Mức 2	Nói lỏng điều kiện loại hình du lịch	Mở rộng các trải nghiệm có liên quan
Mức 3	Mở rộng sang nhóm chi phí gần với ngân sách đã chọn	Tăng số lượng điểm đến ứng viên
Mức 4	Giữ các điều kiện quan trọng nhất và xếp hạng bằng điểm Hybrid	Bảo đảm hệ thống luôn có kết quả

(Nguồn: Tác giả đề xuất.)

Cơ chế Soft Filtering giúp tăng độ bao phủ của kết quả nhưng vẫn ưu tiên các điểm đến thỏa mãn nhiều điều kiện ban đầu hơn. Hệ thống cần hiển thị thông báo khi đã nói lỏng tiêu chí để người dùng hiểu vì sao một số kết quả không khớp hoàn toàn với lựa chọn ban đầu.

3.4.2 Thiết kế API

Hệ thống được xây dựng theo kiến trúc Client–Server, trong đó giao diện người dùng (Frontend) được phát triển bằng ReactJS và giao tiếp với máy chủ (Backend) thông qua các RESTful API. Backend được xây dựng bằng FastAPI, chịu trách nhiệm tiếp nhận yêu cầu từ người dùng, xử lý dữ liệu, thực thi các thuật toán gợi ý và trả kết quả về dưới dạng dữ liệu JSON.

Các API trong hệ thống được thiết kế theo nguyên tắc RESTful, sử dụng giao thức HTTP và các phương thức như GET, POST, PUT và DELETE để thực hiện các chức năng tương ứng. Việc áp dụng kiến trúc REST giúp hệ thống dễ mở rộng, dễ bảo trì và thuận tiện trong việc tích hợp với các ứng dụng khác trong tương lai.

Bảng 3.6 Các endpoint chính của hệ thống.

Nhóm	Method	Endpoint	Mô tả	Xác thực
Auth	POST	/api/auth/register	Đăng ký tài khoản mới	Không
	POST	/api/auth/login	Đăng nhập, trả về JWT token	Không
	POST	/api/auth/forgot-password	Gửi email khôi phục mật khẩu	Không
	POST	/api/auth/reset-password	Đặt lại mật khẩu bằng token	Không
Recommendations	GET	/api/recommendations	Lấy danh sách gợi ý theo bộ lọc (season, budget, category, country, top_n)	Tùy chọn
Destinations	GET	/api/destinations	Lấy danh sách tất cả điểm đến, hỗ trợ tìm kiếm và phân trang	Không

Xây dựng hệ thống gợi ý điểm du lịch quốc tế dựa trên khai phá dữ liệu


Nhóm	Method	Endpoint	Mô tả	Xác thực
	GET	/api/destinations/{id}	Lấy chi tiết một điểm đến theo ID	Không
	POST	/api/destinations/{id}/rate	Người dùng gửi đánh giá (số sao + nhận xét) cho điểm đến	Bắt buộc
	GET	/api/destinations/{id}/weather	Lấy thời tiết hiện tại tại điểm đến qua Weather API	Không
	GET	/api/destinations/{id}/climate	Lấy dữ liệu khí hậu lịch sử theo tháng qua Open-Meteo	Không
	GET	/api/destinations/{id}/similar	Lấy danh sách điểm đến tương tự (cùng cluster K-Means)	Không
Chat	POST	/api/chat	Gửi câu hỏi ngôn ngữ tự nhiên, nhận gợi ý kèm câu trả lời từ Gemini	Tùy chọn
	GET	/api/chat/history	Lấy lịch sử hội thoại của người dùng	Bắt buộc
Admin	GET	/api/admin/stats	Xem thống kê hệ thống (số điểm đến, số lượt, số người dùng)	Admin

Nhóm	Method	Endpoint	Mô tả	Xác thực
	POST	/api/admin/run-clustering	Kích hoạt lại quy trình K-Means với dữ liệu mới	Admin
	POST	/api/admin/run-apriori	Kích hoạt lại quy trình khai phá luật Apriori	Admin

Thông qua việc phân chia API theo từng nhóm chức năng, hệ thống đảm bảo tính độc lập giữa các module, đồng thời tạo điều kiện thuận lợi cho việc mở rộng hoặc nâng cấp các chức năng trong quá trình phát triển sau này.

3.5 Sơ đồ phân rã chức năng

Sơ đồ phân rã chức năng được xây dựng nhằm thể hiện các chức năng của hệ thống theo cấu trúc phân cấp. Từ chức năng tổng quát là hệ thống gợi ý điểm du lịch quốc tế, hệ thống được chia thành năm nhóm chức năng chính gồm quản lý tài khoản và xác thực, gợi ý và tìm kiếm điểm đến, tương tác bản đồ và thông tin chi tiết, trợ lý ảo chatbot AI, quản trị và khai phá dữ liệu.



Hình 3.3 Sơ đồ phân rã chức năng

Sơ đồ phân rã chức năng trình bày toàn bộ chức năng của hệ thống gợi ý du lịch theo cấu trúc phân cấp, trong đó hệ thống được phân rã thành năm nhóm chức năng chính ở cấp độ thứ hai, mỗi nhóm tiếp tục được chi tiết hóa thành các chức năng cụ thể ở cấp độ thứ ba.

Nhóm chức năng quản lý tài khoản và xác thực đảm nhiệm việc quản lý danh tính người dùng trong hệ thống, bao gồm chức năng đăng ký và đăng nhập, cùng chức năng đổi hoặc khôi phục mật khẩu trong trường hợp người dùng quên thông tin xác thực.

Nhóm chức năng gợi ý và tìm kiếm điểm đến giữ vai trò trung tâm của hệ thống, bao gồm bộ máy gợi ý theo phương pháp lai (hybrid) kết hợp nhiều kỹ thuật tính điểm, chức năng tìm kiếm theo từ khóa, chức năng gợi ý theo mùa du lịch và chức năng lọc theo tiêu chí thông qua giao diện wizard cho phép người dùng tùy chỉnh các điều kiện tìm kiếm theo nhu cầu cá nhân.

Nhóm chức năng tương tác bản đồ và chi tiết phục vụ nhu cầu khám phá thông tin chuyên sâu về từng điểm đến, bao gồm chức năng hiển thị bản đồ tương tác được xây dựng bằng thư viện Leaflet.js, chức năng cung cấp dữ liệu thời tiết thời gian thực và dữ liệu khí hậu theo mùa, cùng chức năng cho phép người dùng đánh giá địa điểm đã trải nghiệm.

Nhóm chức năng trợ lý ảo chatbot AI đảm nhiệm việc xử lý ngôn ngữ tự nhiên trong tương tác hội thoại, bao gồm hai chức năng cốt lõi: nhận diện ý định và trích xuất thực thể từ phát ngôn của người dùng và sinh câu trả lời tự nhiên thông qua mô hình Gemini AI, kèm theo phương án dự phòng bằng cơ chế rule-based nhằm đảm bảo tính sẵn sàng của hệ thống khi dịch vụ AI bên ngoài không khả dụng.

Nhóm chức năng quản trị và khai phá dữ liệu phục vụ vai trò quản trị viên hệ thống, bao gồm sáu chức năng: quản trị tài khoản người dùng và dữ liệu đánh giá, khai phá luật kết hợp bằng thuật toán Apriori, phân cụm điểm đến bằng thuật toán K-Means, đồng bộ lại dữ liệu sau khi có cập nhật, tính toán lại ma trận tương đồng phục vụ lọc cộng tác và quản lý hình ảnh cùng tài nguyên đa phương tiện liên quan đến điểm đến.

CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM

4.1 Môi trường thực nghiệm

Hệ thống được triển khai và kiểm thử trên máy tính cá nhân với môi trường phát triển bao gồm cả frontend, backend và cơ sở dữ liệu. Backend được xây dựng bằng FastAPI, frontend sử dụng ReactJS kết hợp Tailwind CSS, cơ sở dữ liệu MongoDB và thư viện Leaflet.js để hiển thị bản đồ.


Quá trình khai phá dữ liệu và huấn luyện các mô hình được thực hiện bằng Python cùng các thư viện Pandas, Scikit-learn và Mlxtend. Mô hình ngôn ngữ Gemini API được tích hợp để xử lý truy vấn bằng ngôn ngữ tự nhiên.

Bảng 4.1 Cấu hình môi trường thực nghiệm của hệ thống

Thành phần	Công nghệ
Frontend	ReactJS + Tailwind CSS
Backend	FastAPI
Database	MongoDB
Ngôn ngữ	Python 3.12
AI	Gemini API
Bản đồ	Leaflet.js
Thuật toán	Apriori, K-Means, TF-IDF

4.2 Kết quả khai phá dữ liệu


Dữ liệu sau tiền xử lý được sử dụng để thực nghiệm Apriori và K-Means. Apriori tạo tập luật phục vụ thành phần điểm luật kết hợp, trong khi K-Means phân nhóm các điểm đến theo đặc trưng chi phí để hỗ trợ chức năng tìm địa điểm tương tự.



Hình 4.1 Phân phối Avg Rating và Avg Cost/Day trên dữ liệu thô (Tourist_Destinations.csv)

Trước khi tiến hành làm sạch, bước đầu tiên trong quy trình là khảo sát phân phối của dữ liệu thô nhằm phát hiện các giá trị bất thường. Biểu đồ bên trái cho thấy Avg Rating tập trung chủ yếu quanh giá trị trung bình 4,49 và lệch về phía cao. Điều này phản ánh đặc điểm thường gặp của dữ liệu đánh giá trong lĩnh vực du lịch, nơi các điểm đến được đưa vào danh mục công khai thường là những địa điểm có mức độ phổ biến và đánh giá tương đối tốt.

Biểu đồ bên phải cho thấy Avg Cost/Day có mức dao động rộng, từ khoảng 30 đến 300 USD/ngày, với giá trị trung bình khoảng 148 USD/ngày. Sự phân tán này tạo điều kiện thuận lợi cho quá trình phân cụm K-Means vì dữ liệu có đủ sự khác biệt về chi phí để hình thành các nhóm điểm đến có ý nghĩa. Việc khảo sát phân phối dữ liệu cũng giúp xác định các ngưỡng lọc giá trị không hợp lệ như rating ngoài khoảng [1,0; 5,0] hoặc chi phí nhỏ hơn hay bằng 0.



Hình 4.2 Phân bố điểm đến theo mức chi phí, loại hình du lịch và châu lục sau khi làm sạch và gán nhãn đặc trưng (1.257 điểm đến)

Sau bước xóa trùng lặp và lọc giá trị không hợp lệ đã trình bày ở Chương 3, dữ liệu được gán thêm các đặc trưng phân loại (Cost_Category, Broader_Type) phục vụ cho cả ba thuật toán khai phá. Ba biểu đồ trong Hình 4.2 cho thấy ba góc nhìn bổ sung cho nhau:

Theo mức chi phí, phân bố lệch mạnh về nhóm Expensive (585) và Moderate (518), trong khi Luxury chỉ chiếm 39 điểm đến - cho thấy tập dữ liệu thiên về phân khúc tầm trung-cao, là điều cần lưu ý khi đánh giá độ đại diện của hệ thống gợi ý cho nhóm người dùng tìm điểm đến giá rẻ. Theo loại hình du lịch, sáu loại hình có số lượng tương đối đồng đều (200–222 điểm đến mỗi loại), cho thấy bước gán nhãn Broader_Type đã tạo ra một tập đặc trưng cân bằng, thuận lợi cho việc xây dựng vector TF-IDF ở module Content-Based Filtering vì không loại hình nào bị áp đảo. Theo châu lục, Asia (23,2%) và Europe (22,3%) chiếm tỷ trọng cao nhất, Oceania thấp nhất (8,8%).

4.2.1 Kết quả thuật toán Apriori


Thuật toán Apriori được thực thi trên ma trận nhị phân gồm 10.050 giao dịch (dữ liệu lịch sử mô phỏng và thao tác người dùng) và 95 thuộc tính (cột True/False đại diện cho các đặc trưng mùa, ngân sách, loại hình, quốc gia và châu lục của từng điểm đến).

Bảng 4.2 Tham số cấu hình thuật toán Apriori

Tham số	Giá trị	Lý do lựa chọn
min_support	0,01	Chỉ giữ lại các tổ hợp đặc điểm xuất hiện ở ít nhất 1% tổng số giao dịch (khoảng 100 trên 10.050 giao dịch), nhằm không bỏ sót những mẫu xuất hiện ít nhưng vẫn có ý nghĩa, đồng thời tránh đặt ngưỡng quá cao khiến những luật kết hợp xuất hiện ít, không phổ biến trên toàn bộ tập dữ liệu nhưng vẫn phản ánh một mối liên hệ có ý nghĩa cho một nhóm nhỏ cụ thể bị loại bỏ ngay từ đầu
min_confidence	0,1	Trong số các điểm đến thỏa điều kiện về trái của luật, chỉ cần tối thiểu 10% trong số đó cũng thỏa điều kiện về phải là được chấp nhận; mức ngưỡng thấp này được chọn có chủ đích để sinh ra nhiều luật ứng viên

Xây dựng hệ thống gợi ý điểm du lịch quốc tế dựa trên khai phá dữ liệu

Tham số	Giá trị	Lý do lựa chọn
		hơn, sau đó dùng min_lift ở bước tiếp theo để lọc lại các luật có ý nghĩa thống kê thực sự
min_lift	1,0	Lift = 1 nghĩa là hai đặc điểm xuất hiện cùng nhau đúng bằng mức ngẫu nhiên, không có liên hệ gì đặc biệt; đặt ngưỡng lift $\geq 1,0$ giúp loại bỏ các luật “giả” - những luật chỉ đúng vì các đặc điểm liên quan vốn đã phổ biến sẵn trong dữ liệu, không phải vì chúng thực sự kéo theo nhau



Hình 4.3 Top 20 thuộc tính có support cao nhất trong ma trận giao dịch (không tính các item thuộc nhóm Country)

Cho thấy Heritage: UNESCO là thuộc tính phổ biến nhất, tiếp theo là Quality:Excellent và Cost:Moderate. Các thuộc tính này đều có support vượt xa ngưỡng min_support = 1%, cho thấy chúng xuất hiện thường xuyên trong tập giao dịch.

Kết quả này cũng giúp giải thích lý do lựa chọn ngưỡng min_support thấp. Nếu sử dụng ngưỡng quá cao, các thuộc tính phổ biến vẫn được giữ lại nhưng những thuộc tính ít xuất hiện hơn, chẳng hạn như một số quốc gia hoặc nhóm khu vực nhỏ, có thể bị loại bỏ. Trong khi đó, các thuộc tính ít phổ biến vẫn có thể phản ánh những mối liên hệ có ý nghĩa đối với một nhóm người dùng cụ thể.

Bảng 4.3 Kết quả thực thi thuật toán Apriori

Xây dựng hệ thống gợi ý điểm du lịch quốc tế dựa trên khai phá dữ liệu


Chỉ số kết quả	Giá trị
Số tập phổ biến (frequent itemsets)	1.368 tập
Số luật khai phá được	5.773 luật

Kết quả thực nghiệm cho thấy thuật toán Apriori đã sinh ra 1.368 tập phổ biến và 5.773 luật kết hợp. Số lượng luật tương đối lớn cho thấy dữ liệu tồn tại nhiều mối quan hệ giữa các thuộc tính du lịch. Tuy nhiên, không phải tất cả các luật đều có giá trị gợi ý như nhau, do đó hệ thống tiếp tục sử dụng các chỉ số Confidence và Lift để đánh giá mức độ hữu ích của từng luật trước khi đưa vào cơ chế tính điểm.

Bảng 4.4 Một số luật kết hợp tiêu biểu

Antecedent (Tiền đề)	Consequent (Kết luận)	Support	Confidence	Lift
{Cost: Budget}	{Continent: Asia}	0,139	0,619	1,99
{Season: Autumn}	{Continent: Asia}	0,103	0,363	1,17
{Season: Spring}	{Continent: Asia}	0,085	0,319	1,02
{Cost: Luxury}	{Continent: Asia}	0,034	0,337	1,08

Các luật cho thấy Asia là khu vực thường xuất hiện trong các luật tiêu biểu, đặc biệt là luật {Cost: Budget} → {Continent: Asia} với confidence đạt 0,619 và lift đạt 1,99. Điều này cho thấy khi điều kiện ngân sách là Budget, khả năng điểm đến thuộc châu Á cao hơn đáng kể so với mức ngẫu nhiên. Kết quả này phù hợp với thực tế vì nhiều điểm đến tại châu Á có chi phí du lịch tương đối thấp hơn so với các khu vực khác.



Hình 4.4 Phân tích chất lượng luật Apriori: tương quan Support–Confidence theo Lift (trái) và phân phối Lift của toàn bộ luật (phải)


Hình thể hiện chất lượng các luật Apriori thông qua mối quan hệ giữa Support, Confidence và Lift. Biểu đồ bên trái cho thấy phần lớn các luật tập trung ở vùng support thấp nhưng confidence trải rộng. Điều này phù hợp với việc lựa chọn min_support thấp nhằm giữ lại nhiều luật ứng viên, sau đó tiếp tục đánh giá bằng Confidence và Lift.

Biểu đồ bên phải cho thấy phần lớn các luật có giá trị Lift gần ngưỡng 1,0, nghĩa là mức độ tương quan chưa quá mạnh. Tuy nhiên, vẫn tồn tại một số luật có Lift cao hơn, thể hiện các mối liên hệ có giá trị khai phá tốt hơn. Vì vậy, trong cơ chế tính điểm Apriori, hệ thống không xem tất cả luật khớp là như nhau mà ưu tiên các luật có Confidence và Lift cao hơn.

4.2.2 Kết quả thuật toán K-Means Clustering

Dữ liệu phân cụm gồm bốn đặc trưng: chi phí trung bình mỗi ngày, chỉ số mức sống, chỉ số giá nhà hàng và chỉ số sức mua nội địa. Điểm đánh giá chỉ được dùng để trực quan hóa và mô tả kết quả, không phải đặc trưng huấn luyện.

Kết quả thực nghiệm cho thấy tại $K = 5$, tốc độ giảm SSE bắt đầu chậm lại, do đó đề tài lựa chọn $K = 5$ để thực hiện phân cụm các điểm đến.



Hình 4.5 Kết quả phân cụm K-Means ($K=5$) trên 359 điểm đến đã hoàn tất làm sạch: phân bố Cost vs Rating theo cụm (trái) và số điểm đến mỗi cụm (phải)

Bảng 4.5 Đặc trưng các cụm K-Means

Cụm	Số điểm đến	Chi phí TB (USD/ngày)	Rating TB	Mức chi phí
-----	-------------	-----------------------	-----------	-------------

Xây dựng hệ thống gợi ý điểm du lịch quốc tế dựa trên khai phá dữ liệu

0	44	222,27	4,76	Expensive
1	106	69,00	4,70	Budget
2	57	151,99	4,97	Expensive
3	27	299,25	4,77	Luxury
4	125	123,21	4,77	Moderate

Thông qua kết quả phân cụm có thể nhận thấy các cụm được hình thành chủ yếu dựa trên sự khác biệt về chi phí trung bình mỗi ngày. Cụm 1 có chi phí trung bình thấp nhất, khoảng 69 USD/ngày, nên được xem là nhóm Budget, phù hợp với người dùng có ngân sách hạn chế. Cụm 4 có chi phí trung bình khoảng 123,21 USD/ngày, thuộc nhóm Moderate, phù hợp với người dùng có nhu cầu du lịch ở mức trung bình. Cụm 2 và cụm 0 có chi phí trung bình lần lượt là 151,99 USD/ngày và 222,27 USD/ngày, thuộc nhóm Expensive, đại diện cho các điểm đến có chi phí cao hơn. Trong khi đó, cụm 3 có chi phí trung bình cao nhất, khoảng 299,25 USD/ngày, thuộc nhóm Luxury, phù hợp với nhóm người dùng có ngân sách cao.

Kết quả này cho thấy thuật toán K-Means đã phân tách được các điểm đến thành những nhóm có mức chi phí khác nhau khá rõ ràng. Tuy nhiên, điểm đánh giá trung bình giữa các cụm không chênh lệch quá lớn, dao động trong khoảng từ 4,70 đến 4,97. Điều này cho thấy yếu tố chi phí là đặc trưng có ảnh hưởng mạnh hơn trong quá trình hình thành cụm, trong khi điểm đánh giá chủ yếu đóng vai trò bổ sung.

Việc phân cụm thành công giúp hệ thống có khả năng mở rộng phạm vi gợi ý. Thay vì chỉ đề xuất một điểm đến duy nhất, hệ thống có thể tìm kiếm thêm các địa điểm khác trong cùng cụm khi người dùng muốn tham khảo nhiều lựa chọn tương tự.

Biểu đồ scatter trực quan hóa rõ cách 5 cụm phân bố theo hai chiều cost và rating: cụm 1 (Budget) và cụm 4 (Moderate) tập trung dày ở vùng chi phí thấp dưới 150 USD/ngày, trong khi cụm 3 (Luxury) trải rộng từ 200 đến gần 300 USD/ngày với số lượng điểm đến ít hơn hẳn (27 điểm đến) - phản ánh đúng quy luật thực tế rằng phân khúc cao cấp luôn chiếm tỷ trọng nhỏ hơn trong thị trường du lịch đại trà. Đáng chú ý, trục rating của cả 5 cụm đều nằm trong khoảng hẹp 4,70–4,97, cho thấy biến rating gần như không có vai trò phân biệt giữa các cụm - yếu tố chi phí mới là biến quyết định chính trong việc hình thành ranh giới cụm, điều này phù hợp với mục tiêu

thiết kế ban đầu là phân cụm theo mức đắt đỏ phục vụ chức năng gợi ý điểm đến tương tự theo chi phí (endpoint /api/destinations/{id}/similar).

Kết quả phân cụm cho thấy phần lớn điểm đến trong hệ thống tập trung ở hai nhóm chi phí thấp và trung bình (cụm 1 và cụm 4 chiếm 231/359 điểm đến, tương đương 64,3%), phản ánh đúng cấu trúc thực tế của tập dữ liệu du lịch đã thu thập.

4.2.3 Liên kết giữa kết quả khai phá dữ liệu và cơ chế tính điểm gợi ý

Apriori và K-Means được sử dụng ở hai nhánh khác nhau. Apriori khai phá các mối liên hệ giữa điều kiện tìm kiếm và thuộc tính điểm đến, sau đó cung cấp tín hiệu cho $Score_{apriori}$. Thuộc tính Cost_Category được tạo trong bước tiền xử lý, không phải từ nhãn K-Means. K-Means chỉ được sử dụng để tìm các điểm đến tương tự thuộc cùng cụm và không trực tiếp tham gia vào công thức $Score_{final}$.

4.2.4 Đánh giá định tính mô hình Hybrid Recommendation

Trong phạm vi đề tài, mô hình Hybrid Recommendation được đánh giá chủ yếu thông qua khả năng vận hành của luồng gợi ý và mức độ phù hợp quan sát được trên một số truy vấn kiểm thử. Content-Based Filtering giữ vai trò chính, Apriori bổ sung tri thức từ luật kết hợp và Collaborative Filtering cung cấp tín hiệu cá nhân hóa khi người dùng có lịch sử đánh giá. Do chưa thực hiện so sánh bằng Precision@K, Recall@K hoặc NDCG, kết quả hiện tại chưa đủ cơ sở để khẳng định mô hình Hybrid tốt hơn từng phương pháp đơn lẻ.


4.3 Kết quả giao diện hệ thống

Sau khi hoàn thiện các module xử lý dữ liệu và xây dựng mô hình gợi ý, hệ thống được triển khai dưới dạng ứng dụng web nhằm cung cấp môi trường tương tác trực quan giữa người dùng và hệ thống. Toàn bộ giao diện được phát triển bằng ReactJS kết hợp Tailwind CSS, trong khi các chức năng xử lý dữ liệu và gợi ý được thực hiện thông qua các REST API do FastAPI cung cấp. Cơ sở dữ liệu MongoDB được sử dụng để lưu trữ thông tin điểm đến, luật kết hợp, nhãn phân cụm và các dữ liệu phục vụ quá trình gợi ý.

Thông qua quá trình kiểm thử, các chức năng của hệ thống đều hoạt động ổn định, tốc độ phản hồi nhanh và đáp ứng đúng yêu cầu đã đặt ra trong giai đoạn phân tích thiết kế.

4.3.1 Trang chủ hệ thống

Trang chủ là giao diện đầu tiên khi người dùng truy cập hệ thống. Giao diện cung cấp thanh điều hướng, tìm kiếm và các điểm đến nổi bật.



Hình 4.6 Giao diện trang chủ


Xây dựng hệ thống gợi ý điểm du lịch quốc tế dựa trên khai phá dữ liệu

Tại trang chủ, hệ thống hiển thị thanh điều hướng, khu vực giới thiệu tổng quan và các điểm đến nổi bật. Người dùng có thể truy cập nhanh đến các chức năng như xem danh sách điểm đến, khám phá bản đồ hoặc sử dụng chức năng gợi ý cá nhân hóa. Việc bố trí các chức năng chính ngay tại trang chủ giúp người dùng dễ dàng bắt đầu quá trình tìm kiếm và lựa chọn điểm đến phù hợp.

Các điểm đến nổi bật được trình bày dưới dạng thẻ thông tin, bao gồm hình ảnh, tên điểm đến, quốc gia, loại hình du lịch, điểm đánh giá và chi phí trung bình. Cách trình bày này giúp người dùng dễ dàng quan sát, so sánh và lựa chọn các địa điểm trước khi xem thông tin chi tiết.

Ngoài ra, trang chủ còn đóng vai trò định hướng trải nghiệm người dùng thông qua các nút chức năng như “Gợi ý cá nhân hóa”, “Xem tất cả điểm đến” và “Khám phá bản đồ”. Nhờ đó, người dùng có thể nhanh chóng chuyển đến các phân hệ quan trọng của hệ thống mà không cần thao tác phức tạp.

4.3.2 Trang các điểm đến



Hình 4.7 Trang điểm đến

Trang danh sách điểm đến được xây dựng nhằm hỗ trợ người dùng tìm kiếm, lọc và khám phá toàn bộ các điểm đến có trong cơ sở dữ liệu.

Ở phía trên giao diện là thanh tìm kiếm cho phép người dùng nhập tên quốc gia hoặc điểm đến. Hệ thống hỗ trợ tìm kiếm theo thời gian thực (Live Search), đồng thời tự động chuyển đổi từ khóa tiếng Việt sang tiếng Anh để tăng độ chính xác khi truy vấn dữ liệu. Nhờ đó, người dùng có thể tìm kiếm nhanh chóng mà không cần nhập đúng tên tiếng Anh của địa điểm.


Bên cạnh thanh tìm kiếm là bộ lọc đa tiêu chí, bao gồm mùa du lịch, mức ngân sách, loại hình du lịch và quốc gia. Các bộ lọc được thiết kế dưới dạng Sidebar trên máy tính và Drawer trên thiết bị di động nhằm tối ưu trải nghiệm trên nhiều kích thước màn hình khác nhau. Khi người dùng thay đổi một tiêu chí, danh sách điểm đến sẽ được cập nhật ngay lập tức mà không cần tải lại toàn bộ trang.

Các điểm đến được trình bày dưới dạng các thẻ thông tin (Destination Card). Mỗi thẻ hiển thị hình ảnh minh họa, tên điểm đến, quốc gia, loại hình du lịch, mức đánh giá, chi phí trung bình và mùa thích hợp để tham quan. Cách trình bày này giúp người dùng dễ dàng so sánh nhiều điểm đến trước khi quyết định xem thông tin chi tiết.

Thông qua việc kết hợp chức năng tìm kiếm, lọc dữ liệu và bố cục trực quan, giao diện danh sách điểm đến giúp giảm đáng kể thời gian tìm kiếm thông tin và hỗ trợ người dùng lựa chọn địa điểm phù hợp với nhu cầu của mình.

4.3.3 Trang chi tiết điểm đến

Trang chi tiết điểm đến được xây dựng nhằm cung cấp cho người dùng thông tin đầy đủ hơn về một địa điểm cụ thể sau khi lựa chọn từ trang danh sách hoặc kết quả gợi ý.



Hình 4.8 Trang chi tiết điểm đến

Giao diện trang chi tiết hiển thị các thông tin chính như hình ảnh đại diện, tên điểm đến, quốc gia, loại hình du lịch, mô tả ngắn, điểm đánh giá trung bình, chi phí trung bình mỗi ngày và thời điểm phù hợp để tham quan. Các thông tin này giúp người dùng có cái nhìn tổng quan trước khi quyết định lựa chọn điểm đến.

Bên cạnh thông tin mô tả, hệ thống còn tích hợp biểu đồ khí hậu nhằm thể hiện nhiệt độ trung bình và lượng mưa theo từng tháng trong năm. Chức năng này giúp người dùng đánh giá điều kiện thời tiết của điểm đến và lựa chọn thời gian du lịch phù hợp hơn.


Ngoài ra, vị trí địa lý của điểm đến được hiển thị trực quan trên bản đồ dựa trên tọa độ kinh độ và vĩ độ. Người dùng có thể quan sát vị trí của địa điểm trên bản đồ, từ đó hình dung rõ hơn về khu vực du lịch và mối liên hệ với các địa điểm lân cận.

Đối với người dùng đã đăng nhập, hệ thống cho phép gửi đánh giá điểm đến thông qua chức năng đánh giá sao. Dữ liệu đánh giá này được lưu trữ trong MongoDB và có thể được sử dụng để bổ sung cho mô hình Collaborative Filtering, góp phần nâng cao khả năng cá nhân hóa của hệ thống trong các lần gợi ý sau.

Xây dựng hệ thống gợi ý điểm du lịch quốc tế dựa trên khai phá dữ liệu

Cuối trang, hệ thống hiển thị các điểm đến tương tự dựa trên nhãn phân cụm K-Means và đặc trưng loại hình du lịch. Chức năng này giúp người dùng có thêm lựa chọn thay thế khi muốn khám phá những địa điểm có đặc điểm gần giống với điểm đang xem.

4.3.4 Trang bản đồ thế giới



Hình 4.9 Trang bản đồ

Trang bản đồ được phát triển dựa trên thư viện Leaflet.js nhằm trực quan hóa vị trí của các điểm đến trên phạm vi toàn thế giới.

Toàn bộ các điểm đến được biểu diễn dưới dạng các Marker trên bản đồ. Khi người dùng lựa chọn một Marker, hệ thống sẽ hiển thị cửa sổ thông tin bao gồm hình ảnh, tên điểm đến, quốc gia, điểm đánh giá và chi phí trung bình.

Bên trái giao diện là khu vực bộ lọc cho phép người dùng lựa chọn mùa du lịch, loại hình, quốc gia hoặc mức ngân sách. Sau khi áp dụng bộ lọc, các Marker trên bản đồ sẽ được cập nhật ngay lập tức, giúp người dùng nhanh chóng xác định các địa điểm đáp ứng tiêu chí tìm kiếm.

Ngoài việc hiển thị vị trí địa lý, bản đồ còn hỗ trợ các thao tác phóng to, thu nhỏ, kéo bản đồ và tự động di chuyển đến điểm đến được lựa chọn. Điều này giúp nâng cao khả năng quan sát và hỗ trợ người dùng xây dựng lịch trình du lịch một cách trực quan hơn.

4.3.5 Trang gợi ý hành trình

Trang gợi ý hành trình là một trong những chức năng quan trọng nhất của hệ thống, được xây dựng nhằm hỗ trợ người dùng lựa chọn điểm đến phù hợp dựa trên các tiêu chí cá nhân. Thay vì phải tự tìm kiếm trong danh sách nhiều điểm đến, người dùng chỉ cần lựa chọn một số thông tin cơ bản như mùa du lịch, phong cách du lịch và ngân sách, sau đó hệ thống sẽ tự động xử lý và đề xuất các điểm đến phù hợp.

Quy trình gợi ý được thiết kế theo dạng từng bước, giúp người dùng dễ dàng thao tác và không bị quá tải thông tin. Ở bước đầu tiên, người dùng lựa chọn mùa du lịch mong muốn như Xuân, Hạ, Thu hoặc Đông. Tiêu chí này giúp hệ thống xác định thời điểm phù hợp để đề xuất các điểm đến có điều kiện khí hậu và trải nghiệm du lịch tương ứng.

Trang chủ Điểm Đến Bản Đồ **Gợi Ý** THẠCH LINH

Gợi Ý Hành Trình

Trả lời 3 câu hỏi ngắn để nhận gợi ý điểm đến được cá nhân hóa bằng AI khai phá dữ liệu.

1 2 3 4

MÙA PHONG CÁCH NGÂN SÁCH KẾT QUẢ

BƯỚC 1 / 3

Bạn muốn đi du lịch vào mùa nào?

Xuân
Tháng 1 – 3 · Tết, lễ hội, dịu mát

Hạ
Tháng 4 – 6 · Nắng đẹp, biển, nghỉ hè


Thu
Tháng 7 – 9 · Mát mẻ, lúa vàng, thanh bình

Đông
Tháng 10 – 12 · Se lạnh, Giáng Sinh

TIẾP THEO →

Hình 4.10 Trang gợi ý hành trình phân chọn mùa

Sau khi lựa chọn mùa, người dùng tiếp tục chọn phong cách du lịch yêu thích. Hệ thống cung cấp nhiều nhóm loại hình như biển và đảo, văn hóa và lịch sử, thiên nhiên, phiêu lưu, nghỉ dưỡng hoặc thành phố. Thông tin này được sử dụng làm đặc trưng đầu vào cho mô hình gợi ý, giúp hệ thống xác định các điểm đến có nội dung tương đồng với sở thích của người dùng.



Hình 4.11 Trang gợi ý hành trình chọn phong cách du lịch


Ở bước tiếp theo, người dùng lựa chọn mức ngân sách trung bình cho chuyến đi. Ngân sách được chia thành các nhóm như tiết kiệm, bình dân, cao cấp và sang trọng. Việc phân nhóm ngân sách giúp hệ thống lọc bỏ các điểm đến không phù hợp về chi phí, đồng thời hỗ trợ quá trình tính điểm gợi ý chính xác hơn.

The screenshot shows a web application for travel recommendations. At the top, there's a navigation bar with links: Trang chủ, Điểm Đến, Bản Đồ, and Gợi Ý (highlighted). A user profile 'THẠCH LINH' is in the top right. The main heading is 'Gợi Ý Hành Trình'. Below it, a subtext says: 'Trả lời 3 câu hỏi ngắn để nhận gợi ý điểm đến được cá nhân hóa bằng AI khai phá dữ liệu.' A progress bar shows four steps: 1. MÙA, 2. PHONG CÁCH, 3. NGÂN SÁCH (current), and 4. KẾT QUẢ. The current step is 'BƯỚC 3 / 3' with the question 'Ngân sách mỗi ngày của bạn là bao nhiêu?'. There are four selectable options: 'TIẾT KIỆM' (< \$50/ngày), 'BÌNH DÂN' (\$50-\$150/ngày), 'CAO CẤP' (\$150-\$300/ngày), and 'SANG TRỌNG' (> \$300/ngày). At the bottom, there are buttons for 'Quay lại' and 'TÌM ĐIỂM ĐẾN PHÙ HỢP'.

Hình 4.12 Trang gợi ý hành trình chọn ngân sách

Sau khi người dùng hoàn thành các tiêu chí lựa chọn, hệ thống gửi dữ liệu về backend để xử lý bằng mô hình Hybrid Recommendation. Quá trình tính toán kết hợp nhiều thành phần gồm Content-Based Filtering, luật kết hợp Apriori và Collaborative Filtering. Trong đó, Content-Based Filtering xác định mức độ tương đồng giữa yêu cầu người dùng và đặc trưng điểm đến; Apriori bổ sung tri thức khai phá từ dữ liệu; Collaborative Filtering hỗ trợ tăng tính cá nhân hóa dựa trên dữ liệu đánh giá của người dùng.

Kết quả gợi ý được hiển thị dưới dạng các thẻ điểm đến. Mỗi thẻ bao gồm hình ảnh, tên điểm đến, quốc gia, loại hình du lịch, điểm đánh giá, chi phí trung bình và các nhãn thể hiện tiêu chí phù hợp. Cách trình bày này giúp người dùng dễ dàng quan sát, so sánh và lựa chọn điểm đến phù hợp với nhu cầu của mình.




Hình 4.13 Trang gợi ý hành trình hiển thị ra gợi ý cho người dùng khi đã chọn đủ các tiêu chí

Thông qua chức năng gợi ý hành trình, hệ thống không chỉ trả về danh sách điểm đến phù hợp mà còn thể hiện được khả năng kết hợp giữa dữ liệu, thuật toán khai phá và giao diện tương tác. Đây là chức năng thể hiện rõ nhất mục tiêu của đề tài trong việc xây dựng một hệ thống gợi ý điểm du lịch quốc tế có khả năng cá nhân hóa cho từng người dùng.

4.3.6 Trang thống kê hệ thống

Trang thống kê hệ thống được xây dựng nhằm hỗ trợ quản trị viên theo dõi tổng quan dữ liệu và kết quả khai phá của hệ thống gợi ý điểm du lịch quốc tế. Giao diện được thiết kế theo dạng Dashboard, giúp các thông tin quan trọng được trình bày trực quan và dễ quan sát.



Hình 4.14 Trang thống kê hệ thống

Trang thống kê hiển thị các chỉ số tổng quan như tổng số điểm đến, số lượng quốc gia, số lượng luật kết hợp Apriori, số lượng người dùng và lượt đánh giá trong hệ thống. Các chỉ số này được lấy trực tiếp từ cơ sở dữ liệu MongoDB, giúp quản trị viên nhanh chóng nắm bắt quy mô và trạng thái dữ liệu hiện tại.

Bên cạnh các thông tin tổng quan, hệ thống còn cung cấp các biểu đồ trực quan nhằm hỗ trợ đánh giá kết quả khai phá dữ liệu. Các biểu đồ như phân bố luật Apriori, quan hệ giữa Support – Confidence – Lift và top các thuộc tính phổ biến giúp quản trị viên phân tích chất lượng tập luật và đặc điểm dữ liệu đầu vào.

Ngoài chức năng thống kê, trang quản trị còn hỗ trợ theo dõi kết quả phân cụm K-Means, quản lý điểm đến, quản lý tài khoản người dùng và xem dữ liệu đánh giá. Nhờ đó, quản trị viên có thể kiểm soát toàn bộ hoạt động của hệ thống trên một giao diện tập trung, đồng thời thuận tiện trong việc cập nhật và bảo trì dữ liệu.

4.4 Đánh giá chung

Hệ thống đã triển khai được các chức năng chính gồm tìm kiếm, lọc, gợi ý cá nhân hóa, chatbot và bản đồ tương tác. Apriori, K-Means và mô hình Hybrid được tích hợp vào Backend và có thể trả kết quả theo luồng thiết kế. Tuy nhiên, chất lượng mô hình vẫn cần được đánh giá thêm bằng các chỉ số định lượng và dữ liệu người dùng thực tế.

CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Kết quả đạt được

Đề tài đã xây dựng được hệ thống gợi ý điểm du lịch quốc tế hoạt động trên nền tảng web. Hệ thống cho phép người dùng tìm kiếm, lựa chọn các tiêu chí như mùa du lịch, ngân sách, loại hình trải nghiệm và nhập yêu cầu bằng ngôn ngữ tự nhiên.

Dữ liệu được thu thập từ nhiều nguồn, sau đó làm sạch, chuẩn hóa và chuyển đổi phù hợp với từng thuật toán. Sau khi loại bỏ dữ liệu trùng lặp, tập dữ liệu chính còn 1.257 điểm đến; trong đó có 359 điểm đến đủ đặc trưng để thực hiện phân cụm K-Means. Dữ liệu Apriori được tổ chức thành ma trận gồm 10.050 giao dịch và 95 item.

Mô hình Hybrid Recommendation kết hợp Content-Based Filtering, luật Apriori và Collaborative Filtering để tính điểm và xếp hạng điểm đến. K-Means hỗ trợ phân nhóm và tìm các điểm đến tương tự, còn Gemini API hỗ trợ phân tích truy vấn bằng ngôn ngữ tự nhiên và tạo phản hồi cho người dùng.

Hệ thống được xây dựng bằng ReactJS, Tailwind CSS, FastAPI và MongoDB, đồng thời tích hợp Leaflet.js để hiển thị điểm đến trên bản đồ. Kết quả thực nghiệm cho thấy các thành phần có thể phối hợp để tiếp nhận yêu cầu và trả về danh sách điểm đến phù hợp.

5.2 Hạn chế

Dữ liệu đánh giá và lịch sử tương tác thực tế của người dùng còn hạn chế nên thành phần Collaborative Filtering chưa phát huy đầy đủ khả năng cá nhân hóa. Tập dữ liệu K-Means chỉ gồm 359 điểm đến có đủ đặc trưng, do đó kết quả phân cụm chưa bao phủ toàn bộ dữ liệu.

Các trọng số trong công thức Hybrid và giá trị tăng cường từ Collaborative Filtering do tác giả đề xuất, chưa được tối ưu tự động trên nhiều tập dữ liệu. Việc đánh giá hệ thống chủ yếu dựa trên kết quả thực nghiệm và kiểm tra chức năng, chưa sử dụng đầy đủ các chỉ số như Precision@K, Recall@K và NDCG.

Ngoài ra, hệ thống chưa tích hợp đầy đủ dữ liệu thay đổi theo thời gian thực như thời tiết, vé máy bay, khách sạn và sự kiện. Việc sử dụng Gemini API còn phụ thuộc vào kết nối Internet và hạn mức của dịch vụ.

5.3 Hướng phát triển

Trong tương lai, hệ thống cần mở rộng dữ liệu điểm đến, đánh giá và lịch sử tương tác từ người dùng thực tế. Các đặc trưng còn thiếu nên được bổ sung để tăng số lượng điểm đến có thể sử dụng trong Apriori, K-Means và Collaborative Filtering.

Mô hình Hybrid cần được đánh giá bằng các chỉ số định lượng và so sánh với từng phương pháp riêng lẻ. Các trọng số trong công thức có thể được lựa chọn bằng phương pháp tối ưu tham số thay vì xác định thủ công.

Hệ thống cũng có thể tích hợp dữ liệu thời tiết, chuyến bay, khách sạn, sự kiện và chi phí theo thời gian thực. Từ đó, chức năng hiện tại có thể được mở rộng từ gợi ý điểm đến sang xây dựng hành trình du lịch hoàn chỉnh, bao gồm thời gian, địa điểm, hoạt động và chi phí dự kiến.

DANH MỤC TÀI LIỆU THAM KHẢO

- [1] Agrawal R., Srikant R. (1994), “Fast Algorithms for Mining Association Rules”, *Proceedings of the 20th International Conference on Very Large Data Bases*, Santiago, Chile, tr. 487–499.
- [2] Amazon Web Services (2024), *What is a Large Language Model?*, Amazon Web Services, <https://aws.amazon.com/vi/what-is/large-language-model/> (Truy cập ngày 23/05/2026).
- [3] Booking.com (2025), *About Booking.com*, Booking Holdings Inc., <https://www.booking.com/content/about.html> (Truy cập ngày 05/05/2026).
- [4] Data Science Process Alliance (2021), *Knowledge Discovery in Databases (KDD) and Data Mining*, Data Science Process Alliance, <https://www.datascience-pm.com/kdd-and-data-mining/> (Truy cập ngày 07/05/2026).
- [5] FastAPI (2025), *FastAPI Documentation*, FastAPI, <https://fastapi.tiangolo.com/> (Truy cập ngày 20/05/2026).
- [6] Fayyad U. M., Piatetsky-Shapiro G., Smyth P. (1996), “From Data Mining to Knowledge Discovery in Databases”, *AI Magazine*, 17(3), tr. 37–54.
- [7] Google (2023), *Gemini API Documentation*, Google AI, <https://ai.google.dev/gemini-api/docs?hl=vi> (Truy cập ngày 22/05/2026).
- [8] Google (2025), *Google Travel*, Google, <https://www.google.com/travel/> (Truy cập ngày 05/05/2026).
- [9] Han J., Kamber M., Pei J. (2012), *Data Mining: Concepts and Techniques*, Ấn bản lần thứ 3, Morgan Kaufmann, Burlington.
- [10] IBM (2023), *Apriori Algorithm*, IBM Think, <https://www.ibm.com/think/topics/apriori-algorithm> (Truy cập ngày 09/05/2026).
- [11] IBM (2023), *What is Collaborative Filtering?*, IBM Think, <https://www.ibm.com/think/topics/collaborative-filtering> (Truy cập ngày 11/05/2026).
- [12] IBM (2023), *What is Content-Based Filtering?*, IBM Think, <https://www.ibm.com/think/topics/content-based-filtering> (Truy cập ngày 11/05/2026).
- [13] Kaggle Inc. (2025), *Tourist Destinations Dataset*, Kaggle Inc., <https://www.kaggle.com/datasets> (Truy cập ngày 02/05/2026).

- [14] Leaflet Contributors (2025), *Leaflet Documentation*, Leaflet, <https://leafletjs.com/> (Truy cập ngày 22/05/2026).
- [15] MacQueen J. (1967), “Some Methods for Classification and Analysis of Multivariate Observations”, *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, Vol. 1, Berkeley, California, tr. 281–297.
- [16] Manning C. D., Raghavan P., Schütze H. (2008), *Introduction to Information Retrieval*, Cambridge University Press, Cambridge.
- [17] mlxtend Developers (2025), *mlxtend Documentation*, <https://rasbt.github.io/mlxtend/> (Truy cập ngày 10/05/2026).
- [18] MongoDB Inc. (2025), *MongoDB Documentation*, MongoDB Inc., <https://www.mongodb.com/docs/> (Truy cập ngày 19/05/2026).
- [19] MongoDB Inc. (2025), *PyMongo Driver Documentation*, MongoDB Inc., <https://www.mongodb.com/docs/languages/python/pymongo-driver/current/> (Truy cập ngày 19/05/2026).
- [20] Nominatim Developers (2025), *Nominatim Documentation*, <https://nominatim.org/> (Truy cập ngày 23/05/2026).
- [21] NumPy Developers (2025), *NumPy Documentation*, <https://numpy.org/doc/> (Truy cập ngày 14/05/2026).
- [22] OpenStreetMap Foundation (2025), *OpenStreetMap*, <https://www.openstreetmap.org/> (Truy cập ngày 23/05/2026).
- [23] Pandas Development Team (2025), *Pandas Documentation*, <https://pandas.pydata.org/docs/> (Truy cập ngày 14/05/2026).
- [24] Public Holidays API (2025), *Public Holidays API Documentation*, <https://date.nager.at/> (Truy cập ngày 06/05/2026).
- [25] Python Software Foundation (2025), *The Python Tutorial*, Python 3.13 Documentation, <https://docs.python.org/3/tutorial/index.html> (Truy cập ngày 13/05/2026).
- [26] Raschka S. (2018), “MLxtend: Providing Machine Learning and Data Science Utilities and Extensions to Python's Scientific Computing Stack”, *Journal of Open Source Software*, 3(24), tr. 638.
- [27] React Team (2025), *React Documentation*, Meta Platforms Inc., <https://react.dev/> (Truy cập ngày 20/05/2026).

- [28] REST Countries (2025), *REST Countries API Documentation*, <https://restcountries.com/> (Truy cập ngày 06/05/2026).
- [29] Ricci F., Rokach L., Shapira B. (2015), *Recommender Systems Handbook*, Ấn bản lần thứ 2, Springer, New York.
- [30] Salton G., Buckley C. (1988), “Term-weighting Approaches in Automatic Text Retrieval”, *Information Processing & Management*, 24(5), tr. 513–523.
- [31] scikit-learn Developers (2025), *Clustering – scikit-learn User Guide*, <https://scikit-learn.org/stable/modules/clustering.html> (Truy cập ngày 16/05/2026).
- [32] scikit-learn Developers (2025), *Feature Extraction – scikit-learn User Guide*, https://scikit-learn.org/stable/modules/feature_extraction.html (Truy cập ngày 17/05/2026).
- [33] Tailwind Labs (2025), *Tailwind CSS Documentation*, <https://tailwindcss.com/docs> (Truy cập ngày 21/05/2026).
- [34] Tripadvisor LLC (2025), *About Tripadvisor*, <https://tripadvisor.mediaroom.com/us-about-us> (Truy cập ngày 05/05/2026).
- [35] Uvicorn Developers (2025), *Uvicorn Documentation*, <https://www.uvicorn.org/> (Truy cập ngày 20/05/2026).
- [36] World Wide Web Consortium (W3C) (2021), *HTML Living Standard*, <https://html.spec.whatwg.org/> (Truy cập ngày 18/05/2026).
- [37] World Wide Web Consortium (W3C) (2024), *CSS Snapshot 2024*, <https://www.w3.org/TR/css-2024/> (Truy cập ngày 18/05/2026).
- [38] Mozilla Foundation (2025), *JavaScript Guide*, <https://developer.mozilla.org/en-US/docs/Web/JavaScript/Guide> (Truy cập ngày 18/05/2026).